

Capsule 3 - Typologie des données

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Comprendre ce que représente une observation dans une base de données.
- Distinguer les principaux types de variables.
- Reconnaître les codes numériques qui ne sont pas des quantités.
- Repérer les premières précautions d'interprétation avant de calculer.

Pourquoi reconnaître les variables?

Le type d'une variable détermine les calculs pertinents, les graphiques utiles et les conclusions raisonnables.

Avant de produire une moyenne, un graphique ou un modèle, il faut savoir ce que chaque colonne mesure, comment elle est codée et ce qu'une ligne représente.

Observation, variable et unité d'analyse

Observation

Une observation correspond à l'unité décrite par une ligne.

Exemples : une journée, une transaction, une succursale, une personne.

Variable

Une variable correspond à une caractéristique mesurée ou codée.

Exemples : nombre, catégorie, date, statut, indicateur temporel.

birth_us.csv

Dans cette base, une ligne correspond à une journée d’observation.

Variable	Sens général
year	année
month	mois
date_of_month	jour dans le mois
day_of_week	jour de la semaine codé
births	nombre de naissances

Variables numériques

Une variable numérique représente une quantité mesurable ou comptable.

- on peut calculer un minimum, une moyenne ou une médiane;
- l'unité de mesure doit être claire;
- les valeurs extrêmes doivent être interprétées avec prudence;
- un graphique peut montrer la distribution des valeurs.

Dans `birth_us.csv`, `births` est une variable numérique : elle compte le nombre de naissances observées pendant une journée.

Variables catégorielles

Une variable catégorielle sert à distinguer des groupes ou des modalités.

- on compte les effectifs ou les proportions;
- on compare des groupes;
- l'ordre des modalités peut être absent ou important;
- les libellés doivent être compréhensibles.

Un jour de semaine peut être traité comme une catégorie : lundi, mardi, mercredi, etc.

Dates et indicateurs temporels

Les variables `year`, `month` et `date_of_month` peuvent être combinées pour former une vraie date.

Date complète

Permet de situer une observation dans le temps et de construire une série chronologique.

Indicateur temporel

Permet de comparer des périodes, par exemple les mois ou les jours de la semaine.

Quand un nombre n'est pas une quantité

Un code numérique peut ressembler à un nombre, sans être une quantité.

Dans `birth_us.csv`, `day_of_week` utilise les nombres 1 à 7. Ces nombres identifient des jours, mais la moyenne de ces codes n'a pas de sens direct.

Un code doit souvent être converti en variable catégorielle avant d'être résumé ou visualisé.

Unités, échelles et interprétation

- nommer l'unité d'observation;
- nommer l'unité de mesure;
- distinguer un total, un taux, un pourcentage et un code;
- éviter de comparer des valeurs qui ne sont pas sur la même échelle.

Comparer des nombres de naissances par journée n'est pas la même chose que comparer des taux ou des proportions.

Premiers signaux de qualité

Avant l'analyse, il faut repérer les signes qui peuvent modifier l'interprétation.

- valeurs manquantes;
- valeurs impossibles ou inattendues;
- changements de codage;
- unités mélangées;
- libellés ambigus.

Ce qui vient ensuite

L'étape suivante portera sur la préparation concrète des données : créer une date, transformer un code en catégorie, vérifier les formats et documenter les transformations.

Dans R, `day_of_week` pourra devenir une variable catégorielle avec des libellés comme lundi, mardi, mercredi, etc.

À retenir

1

Une ligne doit toujours être interprétée comme une unité d'analyse.

2

Le type d'une variable détermine les résumés et les graphiques possibles.

3

Un code numérique n'est pas automatiquement une quantité.

Activité 1.3

Classez les variables de `birth_us.csv` dans un court tableau.

Pour chaque variable, indiquez : son nom, son type, son rôle possible dans une analyse et une précaution d'interprétation.