

Capsule 4 - Préparation des données

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UNE DÉCISION CONCRÈTE

Que vaut une analyse juste menée sur des données mal préparées?

Elle peut donner un résultat faux, mais présenté avec assurance. Trois colonnes de date qu'on ne peut pas trier, un code qu'on moyenne par erreur : la préparation rend les données dignes de confiance avant tout calcul.

Objectifs de la capsule

- Comprendre pourquoi une base se prépare avant d'être résumée.
- Créer une vraie date et transformer un code en catégorie.
- Documenter les transformations pour les rendre reproductibles.

Point de départ : birth_us.csv

Une ligne correspond à une journée. Voir  birth_us.csv.

year

élément de date

month

élément de date

date_of_month

élément de date

day_of_week

code de jour

births

naissances par jour

date

moyenne.

1, ..., 7
↓
lundi dimanche

Préparer avec une intention

Une transformation répond toujours à un besoin d'analyse.

- conserver la variable d'origine pour vérifier;
- créer une nouvelle variable quand le sens devient plus clair;
- nommer et pouvoir expliquer ce qui a changé.

} ancienne
+
nouvelle

↳ documenter.

Deux transformations utiles

CRÉER UNE DATE

`year + month + date_of_month` → `2000-01-01`. La journée devient un repère temporel complet : trier, situer, construire une série.

year - month - date_of_month

CODER EN CATÉGORIE

`day_of_week` (1 à 7) → lundi à dimanche. Le jour devient une catégorie lisible plutôt qu'un nombre à moyenner.

1 → "lundi"
2 → "mardi"
⋮

Le geste en R

(exemple)


```
1 birth <- birth |>
2   mutate(
3     date = make_date(year, month, date_of_month),
4     jour_semaine = factor(
5       day_of_week, levels = 1:7,
6       labels = c("lundi", "mardi", "mercredi", "jeudi",
7                 "vendredi", "samedi", "dimanche")
8     )
9   )
```

La version complète et commentée est montrée dans la [démonstration 1](#).

Vérifier avant de résumer

Vérification	Pourquoi
Valeurs manquantes dans <code>births</code>	éviter un résumé calculé sur une information absente
Codes hors de 1–7, mois hors de 1–12	repérer un codage impossible
Une seule ligne par date	éviter les doublons avant de moyenner

Cette vérification ne remplace pas un nettoyage complet : elle signale les points à examiner.



value manquante $\rightarrow \emptyset$
 erreur.

ex:

code = 8 $\rightarrow$ impossible, 7 jor / semaine.

Documenter les transformations

Reproduire Hbilit

- `date` : créée avec `year`, `month`, `date_of_month`;
- `jour_semaine` : créée à partir de `day_of_week`;
- `births` : conservée comme nombre quotidien;
- variables d'origine gardées pour vérification.

Ce recodage de `jour_semaine` servira dès la capsule 6 à révéler un écart frappant entre la semaine et le week-end.

2 nouvelles variables : `date` et `jour_semaine`.

À retenir

1

Préparer une base, c'est clarifier le sens des variables.

2

Une date complète vaut mieux que trois morceaux de date.

3

Toute transformation doit pouvoir être expliquée et reproduite.

Production autonome 1.4

Décrivez la préparation nécessaire avant de résumer `births`.

Indiquez ce que représente une ligne de `birth_us.csv`, pourquoi `day_of_week` doit être traité comme une catégorie, et quelle vérification faire avant le résumé.

Auto-vérification

- J'ai nommé l'unité d'observation et le type des variables.
- Mon graphique ou mon résumé répond exactement à la question.
- Ma conclusion contient une limite descriptive.