

Capsule 4 - Préparation des données

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Comprendre pourquoi une base doit être préparée avant d'être résumée.
- Créer une vraie date à partir de colonnes séparées.
- Transformer un code numérique en catégorie lisible.
- Documenter les transformations utiles à l'analyse.

Pourquoi préparer la base?

Une base peut être lisible pour un humain sans être directement prête pour l'analyse.

La préparation consiste à rendre explicites les formats, les unités et les codes pour éviter des calculs corrects sur des variables mal interprétées.

Point de départ : `birth_us.csv`

Dans cette base, une ligne correspond à une journée d'observation.

Variable	Rôle avant préparation
<code>year</code>	morceau de date
<code>month</code>	morceau de date
<code>date_of_month</code>	morceau de date
<code>day_of_week</code>	code de jour
<code>births</code>	nombre de naissances

Préparer sans modifier au hasard

Une transformation doit toujours répondre à un besoin d'analyse.

- garder la variable originale si elle est utile pour vérifier;
- créer une nouvelle variable quand le sens devient plus clair;
- nommer la transformation;
- pouvoir expliquer ce qui a changé.

Vérifier les noms et la structure

Avant de transformer, il faut lire la structure de la base.

La question n'est pas seulement : est-ce que R a lu le fichier? Il faut aussi vérifier ce que chaque colonne représente.

Créer une vraie date

Les colonnes `year`, `month` et `date_of_month` décrivent ensemble une date.

Une vraie date permet de trier les observations, de construire une série chronologique et de vérifier les périodes couvertes.

Transformer un code en catégorie

`day_of_week` contient des nombres, mais ces nombres identifient des jours.

Après cette transformation, le jour de la semaine devient une catégorie interprétable plutôt qu'un nombre à moyenner.

Valeurs manquantes et inattendues

Une première vérification cherche les valeurs absentes ou impossibles.

Cette vérification ne remplace pas un nettoyage complet. Elle signale les points à examiner avant de produire des résumés.

Cohérence temporelle et doublons

Une base quotidienne devrait avoir une seule observation par date.

Si une date apparaît deux fois, il faut comprendre pourquoi avant de calculer une moyenne ou de produire une série temporelle.

Documenter les transformations

- `date` : créée avec `year`, `month` et `date_of_month`;
- `jour_semaine` : créée à partir du code `day_of_week`;
- `births` : conservée comme nombre de naissances quotidiennes;
- les variables originales restent disponibles pour vérification.

Une transformation documentée peut être relue, corrigée et reproduite.

Code R minimal

Ce code prépare seulement ce qui est nécessaire pour la suite immédiate : résumer les naissances et comparer les jours de la semaine.

Ce que la préparation permet

1

Situer chaque observation dans le temps.

2

Comparer les jours comme des catégories.

3

Produire des résumés plus faciles à interpréter.

À retenir

- Préparer une base, c'est clarifier le sens des variables.
- Une date complète est plus utile que trois morceaux de date.
- Un code numérique peut représenter une catégorie.
- Toute transformation doit pouvoir être expliquée.

Activité 1.4

Préparez mentalement la base avant de résumer `births`.

Indiquez ce que représente une ligne de `birth_us.csv`, expliquez pourquoi `day_of_week` doit être traité comme une catégorie et nommez une vérification à faire avant de produire un résumé descriptif.