

Capsule 5 - Exploration univariée

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Résumer une variable numérique avec quelques indicateurs simples.
- Distinguer ce que la moyenne et la médiane montrent.
- Construire un histogramme pour observer la distribution.
- Écrire un constat descriptif sans dépasser ce que la base permet de dire.

Pourquoi décrire une variable?

Avant de comparer ou de modéliser, il faut comprendre chaque variable importante prise séparément.

Une analyse univariée répond à une première question simple : quelles valeurs observe-t-on pour une variable donnée?

De la base préparée à l'analyse

À cette étape, la base a déjà été lue, comprise et préparée.

- une ligne correspond à une journée;
- `date` situe l'observation dans le temps;
- `jour_semaine` décrit une catégorie;
- `births` donne le nombre de naissances observées.

La variable **births**

births est une variable numérique.

Question	Réponse attendue
Que mesure la variable?	un nombre de naissances
Pour quelle unité?	une journée
Quelle échelle?	un dénombrement
Peut-on faire une moyenne?	oui, avec interprétation prudente

Résumer une variable numérique

min

plus petite valeur observée

moy.

niveau moyen observé

méd.

valeur centrale robuste

max

plus grande valeur observée

Minimum, moyenne, médiane et maximum

```
1 birth_prepare |>
2   summarise(
3     jours = n(),
4     naissances_min = min(births, na.rm = TRUE),
5     naissances_moyennes = mean(births, na.rm = TRUE),
6     naissances_medienes = median(births, na.rm = TRUE),
7     naissances_max = max(births, na.rm = TRUE)
8   )
```

Ces indicateurs décrivent la variable. Ils ne disent pas encore pourquoi les naissances varient d'une journée à l'autre.

Moyenne et médiane

La moyenne utilise toutes les valeurs. La médiane coupe les observations en deux groupes de même taille.

Quand la moyenne et la médiane sont proches, cela suggère un centre assez stable. Quand elles sont très différentes, il faut regarder la distribution avant d'interpréter.

Tableau descriptif minimal

```
1 resume_births <- birth_prepare |>
2   summarise(
3     jours = n(),
4     minimum = min(births, na.rm = TRUE),
5     moyenne = mean(births, na.rm = TRUE),
6     mediane = median(births, na.rm = TRUE),
7     maximum = max(births, na.rm = TRUE)
8   )
9
10 resume_births
```

Un tableau descriptif est utile s'il reste lié au sens de la variable et à l'unité d'observation.

Histogramme : voir la distribution

```
1 birth_prepare |>
2   ggplot(aes(births)) +
3   geom_histogram(bins = 30, fill = "#2A9D8F", color = "white") +
4   labs(
5     title = "Distribution quotidienne du nombre de naissances",
6     x = "Nombre de naissances",
7     y = "Nombre de jours"
8   ) +
9   theme_minimal(base_size = 12)
```

L'histogramme montre la forme générale : concentration des valeurs, asymétrie possible et valeurs inhabituelles.

Classes de l'histogramme

Un histogramme regroupe les valeurs numériques en classes.

- Trop peu de classes peuvent cacher des détails.
- Trop de classes peuvent créer du bruit visuel.
- Le choix doit aider à voir la structure générale.

Changer **bins** ne change pas la base. Cela change la manière de regarder la distribution.

Valeurs inhabituelles

Une valeur très petite ou très grande mérite d'être examinée avant d'être expliquée.

Repérer une valeur inhabituelle ne suffit pas pour conclure à une erreur, à une cause particulière ou à un phénomène exceptionnel.

Écrire un constat prudent

Phrase acceptable : la variable `births` décrit un nombre quotidien de naissances et ses valeurs se concentrent autour d'un niveau central visible dans le tableau descriptif et l'histogramme.

Évitez les explications causales à cette étape. On décrit ce qui est observé dans la base.

Lien avec la suite

Après avoir décrit une variable, on peut comparer cette variable selon une autre variable.

- `births` seule : analyse univariée;
- `births` selon `jour_semaine` : comparaison entre groupes;
- la comparaison demande une interprétation encore plus prudente.

À retenir

- Une analyse univariée décrit une variable à la fois.
- Le tableau descriptif et le graphique se complètent.
- La moyenne et la médiane n'ont pas exactement le même rôle.
- Un constat descriptif ne doit pas devenir une explication causale.

Production autonome 1.5

Produisez une courte analyse univariée de `births`.

Incluez un tableau avec le minimum, la moyenne, la médiane et le maximum, un histogramme, une phrase descriptive prudente et une limite d'interprétation.

Auto-vérification : l'analyse est complète si le tableau et l'histogramme décrivent la même variable, si la phrase reste descriptive et si la limite évite d'expliquer les causes des variations observées.