

Capsule 6 - Comparer prudemment

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UNE DÉCISION CONCRÈTE

La compagnie A a 6 incidents, la compagnie B en a 1. A est-elle plus dangereuse?

Impossible à dire sans connaître leur taille. Si A vole dix fois plus que B, son taux peut être plus faible. Comparer sans tenir compte de l'échelle mène à de fausses conclusions.

Objectifs de la capsule

- Comparer une variable numérique selon une catégorie.
- Distinguer un nombre brut d'un indicateur ajusté à l'échelle.
- Formuler une limite d'interprétation claire.

Comparer births selon jour_semaine

On compare une variable numérique (`births`) selon une variable catégorielle (`jour_semaine`).

centre

médiane de chaque jour


étendue

dispersion visible

écarts

comparaison entre groupes

Graphique de comparaison



Le constat, et sa limite

CONSTAT DESCRIPTIF

Le samedi et le dimanche ont des niveaux nettement plus bas que les jours de semaine.

LIMITE

Le graphique décrit cet écart ; il n'explique pas pourquoi il existe.

C'est l'écart qui produisait les deux bosses de l'histogramme de la capsule 5.

Nombre brut et échelle

Dans `safety_airlines.csv`, les compagnies n'ont ni la même taille ni la même exposition.

Indicateur	Ce qu'il mesure
<code>incidents_00_14</code>	nombre brut d'incidents
<code>avail_seat_km_per_week</code>	volume d'activité hebdomadaire
<code>incidents_par_milliard</code>	incidents par milliard de sièges-km estimés

Pourquoi un taux indicatif?

Un taux ramène les incidents à une échelle commune : incidents ÷ exposition. Il rend les compagnies comparables.

L'exposition est **approximée** : on applique un volume hebdomadaire récent à 15 ans (2000–2014). Utile pour l'ordre de grandeur, pas pour une mesure exacte de la sécurité.

Comparer deux classements

Compagnie	Incidents 2000-2014	Taux indicatif
Pakistan International	10	0.037
Saudi Arabian	11	0.016
Sri Lankan / AirLanka	4	0.016
Ethiopian Airlines	5	0.013
Gulf Air	3	0.013
Royal Air Maroc	3	0.013

Si le classement change entre le nombre brut et le taux, c'est que l'échelle de comparaison influence l'interprétation.

La même logique en gestion

NOMBRE BRUT

120 plaintes, 8 défauts, 50 000 \$ de ventes.

RAMENÉ À UNE BASE COMMUNE

Plaintes par 1 000 clients, défauts par lot, ventes par employé.

Brut vs taux : même grille de lecture en ventes, en qualité ou en RH.

Association et causalité

- un boxplot décrit des écarts entre groupes;
- un taux décrit un indicateur sur une échelle commune;
- une cause demande d'autres informations et une analyse adaptée.

Une comparaison descriptive peut révéler une association. Elle ne démontre pas une cause.

À retenir

1

Comparer demande de nommer les variables et l'échelle.

2

Un nombre brut peut être trompeur sans contexte ; un taux ramène à une base commune.

3

Une comparaison descriptive ne prouve pas une cause.

Production autonome 1.6

Produisez deux constats descriptifs et une limite.

Comparez `births` selon `jour_semaine`, puis `incidents_00_14` au taux indicatif dans `safety_airlines.csv`. Terminez par une limite.

Auto-vérification : le travail est complet si chaque constat nomme les variables comparées, précise l'échelle utilisée et évite de transformer une comparaison descriptive en conclusion causale.