

Semaine 01 - Comprendre une base avant de modéliser

MQT-2101 - Analyse et modélisation des données

Objectifs de la séance

Cette première séance installe un réflexe simple : avant de modéliser, il faut savoir ce qu'une base décrit, comment les variables sont codées et ce que les résumés permettent réellement de conclure.

1

nommer l'unité d'observation

2

classer les variables

3

décrire et comparer prudemment

Le fil conducteur

DÉPART

ouvrir la base

LIRE

une ligne = quoi?

PRÉPARER

rendre les
variables
interprétables

DÉCRIRE

résumer une
variable

COMPARER

changer l'échelle
avec prudence

TRACE

garder une preuve
courte

La trace de portfolio ne doit pas tout recopier. Elle doit montrer que vous avez compris le passage de la base brute à un constat descriptif défendable.

Pourquoi commencer par la base?

Un modèle peut être techniquement correct et répondre à la mauvaise question.

AVANT LE CALCUL

Que représente une ligne? Quelle variable mesure quoi?
Quelle comparaison est raisonnable?

APRÈS LE CALCUL

Le résultat décrit-il la base, une association, une prévision ou une cause?

Partie 1 : lire la base

POINT DE DÉPART

Une ligne de `birth_us.csv`

Dans cette base, une ligne correspond à une journée d'observation.

<code>year</code> 2000	<code>month</code> 1	<code>date_of_month</code> 1	<code>day_of_week</code> 6	<code>births</code> 9083
----------------------------------	--------------------------------	--	--------------------------------------	------------------------------------

La même ligne contient des morceaux de date, un code de jour et un nombre de naissances. Ces colonnes ne se résument pas toutes de la même façon.

Observation et variable

OBSERVATION

L'unité décrite par une ligne. Ici : une journée.

VARIABLE

Une caractéristique décrite par une colonne. Ici : année, mois, jour, code de semaine, naissances.

UNITÉ DE MESURE

Ce que les valeurs mesurent. Ici, `births` est un nombre quotidien de naissances.

RÔLE POSSIBLE

Une variable peut servir à décrire, à grouper, à comparer ou à situer dans le temps.

Lire quelques lignes

year	month	date_of_month	day_of_week	births
1994	1	1	6	8096
1994	1	2	7	7772
1994	1	3	1	10142
1994	1	4	2	11248
1994	1	5	3	11053

L'objectif n'est pas encore de calculer. L'objectif est de comprendre la structure de la base.

Types de variables

NUMÉRIQUE

Une quantité ou une mesure. Exemple : `births`.

CATÉGORIELLE

Des groupes ou modalités. Exemple : jour de la semaine.

DATE

Un repère temporel complet. Exemple : 2000-01-01.

CODE

Un nombre qui identifie une catégorie. Exemple : `day_of_week`.

Quand un nombre n'est pas une quantité

`day_of_week` contient des nombres de 1 à 7. Pourtant, la moyenne de ces codes n'a pas de sens utile.

À ÉVITER

La moyenne de `day_of_week` est 4, donc le jour moyen est jeudi.

À FAIRE

Transformer le code en catégorie : lundi, mardi, mercredi, etc.

Partie 2 : préparer sans trahir

RENDRE LA BASE INTERPRÉTABLE

Préparer, c'est rendre explicite

AVANT

year, month,
date_of_month

APRÈS

une vraie variable
date

AVANT

day_of_week = 1
à 7

APRÈS

jour_semaine =
catégorie lisible

AVANT

variables brutes

APRÈS

base prête à
résumer

Code minimal de préparation

```
1 birth_prepare <- birth_us |>
2   mutate(
3     date = make_date(year, month, date_of_month),
4     jour_semaine = factor(
5       day_of_week,
6       levels = 1:7,
7       labels = c(
8         "lundi", "mardi", "mercredi", "jeudi",
9         "vendredi", "samedi", "dimanche"
10      )
11    )
12  )
```

On ne modifie pas au hasard. On crée des variables plus utiles pour répondre aux questions de la semaine.

Vérifications rapides

Lignes	Dates distinctes	Valeurs manquantes	Codes inattendus
3652	3652	0	0

Ces vérifications ne prouvent pas que la base est parfaite. Elles évitent de résumer une variable mal lue ou mal codée.

Partie 3 : décrire une variable

ANALYSE UNIVARIÉE

La question devient plus précise

Que peut-on dire du nombre quotidien de naissances observé dans la base?

VARIABLE ÉTUDIÉE

births

UNITÉ D'OBSERVATION

une journée

RÉSUMÉS UTILES

minimum, moyenne, médiane, maximum

GRAPHIQUE UTILE


histogramme de la distribution

Résumé numérique

jours	minimum	moyenne	mediane	maximum
3652	6443	10876.8	11615	14540

La moyenne donne un niveau moyen. La médiane donne une valeur centrale moins sensible aux valeurs très petites ou très grandes.

Histogramme de births



La ligne noire marque la médiane. Le graphique aide à voir la concentration des valeurs et les journées plus inhabituelles.

Écrire un constat prudent

ACCEPTABLE

Dans cette base, `births` décrit un nombre quotidien de naissances. Le tableau et l'histogramme résument les valeurs observées sans expliquer leurs causes.

TROP FORT

Le graphique prouve pourquoi certains jours ont moins de naissances.

Au module 1, on apprend surtout à décrire et à limiter l'interprétation.

Partie 4 : comparer prudemment

ANALYSE BIVARIÉE DESCRIPTIVE

Comparer, c'est changer la question

Les naissances observées semblent-elles varier selon le jour de la semaine?

VARIABLE NUMÉRIQUE

births

VARIABLE DE GROUPE

jour_semaine


GRAPHIQUE

boxplots côte à côte

LIMITE

un écart visible n'est pas une explication causale

births selon le jour




Le boxplot compare les distributions. Il attire l'attention sur les centres, les dispersions et les valeurs plus extrêmes.

Nombre brut ou taux?

Dans `safety_airlines.csv`, un nombre brut d'incidents ne tient pas compte de la taille des compagnies ni de leur volume d'activité.

airline	incidents_00_14	incidents_par_milliard
Pakistan International	10	0.037
Saudi Arabian	11	0.016
Sri Lankan / AirLanka	4	0.016
Ethiopian Airlines	5	0.013
Gulf Air	3	0.013

Même base, deux lectures



Changer d'échelle peut changer l'histoire racontée par les données. C'est exactement pour cela qu'il faut nommer l'indicateur utilisé.

Partie 5 : produire une trace

PORTFOLIO

Ce que la trace doit montrer

1. BASE

Je sais dire ce que représente une ligne.

2. VARIABLES

Je sais classer quelques variables et nommer une précaution.

3. RÉSUMÉ

Je sais produire un tableau descriptif et un graphique.

4. INTERPRÉTATION

Je sais écrire deux constats descriptifs et une limite.

Exemple de limite utile

PHRASE UTILISABLE

Ces résultats décrivent les valeurs observées dans la base. Ils ne permettent pas, à eux seuls, d'expliquer les causes des différences observées ni de généraliser à un autre contexte.

Une limite n'affaiblit pas l'analyse. Elle montre que l'interprétation est maîtrisée.

Trois réflexes à garder

1

nommer l'unité avant de calculer

2

adapter le résumé au type de variable

3

écrire ce que le résultat ne permet pas de conclure

Production autonome

À partir de vos exercices, préparez une trace de portfolio d'une page maximum.
La trace doit pouvoir être comprise sans explication orale.

- une phrase sur le rôle d'un modèle;
- un classement de quelques variables;
- un tableau descriptif et un graphique;
- deux constats descriptifs;
- une limite d'interprétation.

Auto-vérification : la trace est suffisante si une autre personne peut nommer la base utilisée, comprendre ce que représente une ligne, voir le résultat produit et repérer clairement ce que l'analyse ne permet pas de conclure.

À conserver

MQT-2101

Avant de passer au module suivant, gardez une version stable de votre trace et notez une notion à consolider dans vos propres mots.