

Capsule 4 - Importer et inspecter un tableau

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UNE DÉCISION CONCRÈTE

Comment savoir si R a vraiment lu ce que vous croyez avoir importé?

Une importation sans erreur ne garantit pas que le tableau a été lu comme prévu. Vérifiez ses dimensions, les types de variables et ce que représente une ligne avant de calculer.

Objectifs de la capsule

- Importer un fichier CSV dans R.
- Nettoyer les noms de variables.
- Inspecter les dimensions, les types et l'unité d'observation.

Le tableau utilisé

- Données simulées pour quatre succursales fictives au Québec.
- Six mois, de janvier à juin 2025.
- Une ligne représente une succursale pendant un mois.
- Ventes en dollars canadiens; satisfaction sur 10.

Importer le fichier

```
1 library(tidyverse)
2 library(janitor)
3
4 ventes_operations <- readr::read_csv(
5   "data/ventes_operations_quebec.csv",
6   show_col_types = FALSE
7 ) |>
8   clean_names()
```



Pourquoi `clean_names()` ?

Cette fonction normalise les noms de colonnes : espaces, majuscules et accents deviennent plus faciles à gérer dans le code. Elle ne nettoie pas les valeurs du tableau.

```
1 # Exemple miniature pour voir la transformation des noms
2 tibble("Délai moyen" = 3, "Ventes CAD" = 100) |>
3   clean_names() |>
4   knitr::kable()
```

delai_moyen	ventes_cad
3	100

Dans notre CSV, les noms sont déjà normalisés : `clean_names()` les conserve.

Inspecter avec `glimpse()`

```
1 glimpse(ventes_operations)
```

Rows: 24

Columns: 12

```
$ mois          <date> 2025-01-01, 2025-01-01, 2025-01-01, 2025-01-01,...
$ mois_nom      <chr> "janvier", "janvier", "janvier", "janvier", "fév...
$ succursale    <chr> "Montréal", "Québec", "Sherbrooke", "Trois-Riviè...
$ region        <chr> "Montréal", "Capitale-Nationale", "Estrie", "Mau...
$ surface_m2    <dbl> 540, 420, 360, 335, 540, 420, 360, 335, 540, 420...
$ campagne_locale <chr> "non", "oui", "non", "non", "non", "non", "oui",...
$ canal_principal <chr> "magasin", "magasin", "web", "web", "web", "maga...
$ clients       <dbl> 2254, 1858, 1506, 1199, 2162, 1682, 1585, 1458, ...
$ panier_moyen  <dbl> 53.11, 59.40, 63.31, 68.21, 66.53, 55.20, 58.44,...
$ ventes        <dbl> 119710, 110365, 95345, 81784, 143838, 92846, 926...
$ delai_livraison_jours <dbl> 2.2, 3.8, 4.5, 3.5, 3.6, 1.8, 3.5, 2.6, NA, 3.9,...
$ satisfaction  <dbl> 8.3, 8.6, 7.3, 8.1, NA, 7.9, 7.8, 8.0, 7.7, 7.9,...
```

`glimpse()` montre en un coup d'œil les colonnes, leurs types et quelques valeurs.

Dimensions et unité d'observation

```
1 dim(ventes_operations)
```



```
[1] 24 12
```

Première valeur : le nombre de lignes. Deuxième valeur : le nombre de colonnes. Ici, une ligne correspond à une succursale pour un mois.

Lire une chaîne de commandes

- `<-` enregistre le résultat dans un objet nommé.
- `|>` transmet le résultat de gauche à la fonction suivante.
- Ici, R lit le CSV, nettoie les noms, puis crée `ventes_operations`.
- `show_col_types = FALSE` masque le message de types, pas les données.

Types de variables à repérer

Type	Exemples dans le tableau
Date ou période	mois
Catégorie	succursale, region, canal_principal
Numérique	clients, ventes, delai_livraison_jours, satisfaction
Indicateur	campagne_locale

À retenir

1

Le code d'importation reste dans le `.qmd`.

2

`clean_names()` et `glimpse()` préparent et inspectent.

3

L'unité d'observation se nomme avant toute analyse.

Production autonome 2.4

Importez `ventes_operations_quebec.csv` et décrivez le tableau.

Indiquez : le code d'importation, le nombre de lignes, le nombre de colonnes et ce que représente une ligne.

Auto-vérification

- Le tableau contient 24 lignes et 12 colonnes.
- Une ligne représente une succursale pendant un mois.
- Je distingue le type informatique et le sens d'une variable.