

Capsule 5 - Résumer et diagnostiquer les données

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UNE DÉCISION CONCRÈTE

Cette succursale a-t-elle vraiment les meilleures ventes, ou des données manquantes faussent-elles le portrait?

Un classement bâti sur des colonnes incomplètes peut désigner le mauvais gagnant. Avant de comparer, on prépare les types de variables et on repère ce qui manque.

Objectifs de la capsule

- Préparer les types de variables utiles.
- Repérer et signaler les valeurs manquantes.
- Produire un tableau descriptif par groupe et l'interpréter prudemment.

Préparer avant de résumer

Un résumé est plus fiable quand les types de variables sont explicites.

Vérifier la structure préparée

```
# A tibble: 1 × 6
  nb_lignes nb_succursales nb_regions nb_canaux mois_min mois_max
  <int>      <int>         <int>    <int> <date>    <date>
1      24         4           4        3 2025-01-01 2025-06-01
```

Repérer les valeurs manquantes

Une valeur manquante peut modifier une moyenne, un total ou une conclusion. Cette semaine, on ne les impute pas encore : on les repère et on les signale.

```
# A tibble: 2 × 2
  variable      valeurs_manquantes
  <chr>          <int>
1 delai_livraison_jours          1
2 satisfaction                  2
```


Interpréter le diagnostic

- nommer les variables incomplètes;
- dire quels indicateurs peuvent être touchés;
- n'utiliser `na.rm = TRUE` que si la décision est signalée.

Résumer par succursale

succursale	region	ventes_totales	clients_totaux	panier_moyen	satisfaction_moyenne
Montréal	Montréal	831 777 \$	14057	59,24 \$	8.1
Québec	Capitale-Nationale	677 971 \$	11464	59,02 \$	8.1
Sherbrooke	Estrie	589 922 \$	9565	61,71 \$	7.9
Trois-Rivières	Mauricie	515 975 \$	8589	60,35 \$	8.2

Lire un tableau descriptif

- repérer la succursale aux ventes les plus élevées;
- comparer panier moyen et satisfaction;
- vérifier si le même groupe ressort pour tous les indicateurs;
- formuler une limite de comparaison.

À retenir

1

Préparer les variables évite des erreurs de calcul.

2

Les valeurs manquantes se signalent, ne se cachent pas.

3

Un tableau descriptif se lie à une question et à une limite.

Production autonome 2.5

Diagnostiquez et résumez le tableau préparé.

Ajoutez : un tableau de diagnostic des valeurs manquantes, un tableau descriptif par succursale ou par canal, et une phrase de précaution d'interprétation.

Auto-vérification : votre travail est complet si le diagnostic nomme les variables incomplètes, si le tableau descriptif répond à une question claire et si la limite évite toute conclusion causale.