

Capsule 5 - Résumer et diagnostiquer les données

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Préparer les types de variables utiles.
- Repérer les valeurs manquantes.
- Produire un tableau descriptif par groupe.
- Interpréter un diagnostic sans masquer les limites.

Préparer avant de résumer

Un résumé est plus fiable lorsque les types de variables sont explicites.

Vérifier la structure préparée

```
# A tibble: 1 × 6
  nb_lignes nb_succursales nb_regions nb_canaux mois_min mois_max
  <int>      <int>         <int>      <int> <date>    <date>
1         24           4           4          3 2025-01-01 2025-06-01
```

Pourquoi diagnostiquer les valeurs manquantes?

Une valeur manquante peut modifier une moyenne, un total, un graphique ou une conclusion descriptive.

Pour cette semaine, on ne cherche pas encore à imputer les valeurs. On apprend à les repérer et à les signaler.

Compter les valeurs manquantes

```
# A tibble: 2 × 2
  variable      valeurs_manquantes
  <chr>          <int>
1 delai_livraison_jours            1
2 satisfaction                    2
```

Interpréter le diagnostic

- Nommer les variables incomplètes.
- Dire quels indicateurs peuvent être touchés.
- Utiliser `na.rm = TRUE` seulement si la décision est signalée.
- Éviter d'ignorer les valeurs manquantes dans le texte.

Résumer par succursale

succursale	region	ventes_totales	clients_totaux	panier_moyen	satisfaction_moyenne
Montréal	Montréal	831 777 \$	14057	59,24 \$	8.1
Québec	Capitale-Nationale	677 971 \$	11464	59,02 \$	8.1
Sherbrooke	Estrie	589 922 \$	9565	61,71 \$	7.9
Trois-Rivières	Mauricie	515 975 \$	8589	60,35 \$	8.2

Lire un tableau descriptif

Un tableau descriptif sert à comparer quelques indicateurs, pas à tout commenter.

- Repérer la succursale avec les ventes les plus élevées.
- Comparer le panier moyen et la satisfaction.
- Vérifier si un même groupe ressort pour tous les indicateurs.
- Formuler une limite de comparaison.

Activité 2.5

Diagnostiquer et résumer

Dans votre trace, ajoutez :

- un tableau de diagnostic des valeurs manquantes;
- un tableau descriptif par succursale ou par canal;
- une phrase qui explique une précaution d'interprétation.

À retenir

- Préparer les variables aide à éviter des erreurs de calcul.
- Les valeurs manquantes doivent être signalées.
- Un tableau descriptif doit être lié à une question.
- Une interprétation prudente nomme aussi une limite.