

Capsule 1 - Formuler une question de régression

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Distinguer question d'affaires et question statistique.
- Identifier la variable réponse et la variable explicative.
- Éviter une formulation causale trop rapide.
- Préparer le nuage de points du module.

Point de départ

Une régression linéaire commence par une question qui relie deux variables. Ici, on veut savoir comment les ventes varient en moyenne lorsque le budget marketing varie.

Deux rôles différents

- Variable réponse : `ventes`, ce que l'on veut expliquer ou prédire.
- Variable explicative : `budget_marketing`, l'indicateur utilisé pour résumer la relation.
- Variables de contexte : `region`, `canal`, `rabais`, `visites_site`.

Bonne formulation

Question prudente : dans ces données, les ventes moyennes sont-elles plus élevées lorsque le budget marketing est plus élevé?

Formulation à éviter

Formulation trop forte : est-ce que le budget marketing cause l'augmentation des ventes? Cette question exige un plan d'étude causal, pas seulement une régression descriptive.

Trace à produire

- Nommer `ventes` comme variable réponse.
- Nommer `budget_marketing` comme variable explicative principale.
- Écrire une phrase qui parle d'association moyenne.
- Ajouter une limite : le modèle ne prouve pas la causalité.

Activité 3.1

Rédigez la question d'analyse en une phrase, puis indiquez la variable réponse, la variable explicative et une variable de contexte qui pourrait modifier l'interprétation.

À retenir

- Une régression répond à une question structurée.
- La variable réponse et la variable explicative ne jouent pas le même rôle.
- La prudence commence dans la formulation de la question.