

Capsule 2 - Lire le nuage de points

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

La relation peut-elle se résumer par une droite?


Avant d'ajuster un modèle, le nuage de points révèle la **forme de la relation** et les écarts entre observations.

régression **linéaire** $\Rightarrow$ droite

Objectifs de la capsule

- Décrire la direction, la forme et la dispersion.
- Lire une corrélation linéaire.
- Repérer les limites d'un résumé numérique.


Lecture du nuage de points



Trois repères visuels


Direction

Association positive



Forme

Tendance approximativement linéaire



Dispersion

Des ventes différentes à budget voisin



Un point éloigné mérite une vérification, pas une suppression automatique.

La corrélation linéaire

r décrit la direction et l'intensité de la relation linéaire.

$$-1 \leq r \leq 1$$

-1

Alignement décroissant




0

Absence de relation linéaire

+1

Alignement croissant

Sans unité. Symétrique en x et y . Une relation courbe peut avoir une corrélation faible.




La corrélation dans ce fichier

```
1 cor(campagnes$budget_marketing, campagnes$ventes)
```

```
[1] 0.907859
```

Ici, r vaut environ 0,908 : l'association linéaire est positive et marquée.

Les régions dans le graphique



Région ● Capitale-Nationale ● Estrie ● Mauricie ● Montréal ● Outaouais

Le code du graphique

```
1 ggplot(campagnes, aes(budget_marketing, ventes)) +  
2   geom_point(aes(colour = region), alpha = 0.8) +  
3   labs(x = "Budget marketing mensuel ($)",  
4        y = "Ventes mensuelles ($)", colour = "Région") +  
5   theme_minimal()
```

L'importation et le code complet figurent dans les démonstrations R.

À retenir

1

Le graphique avant le calcul

2

Une corrélation sans unité

3

Le contexte reste nécessaire

Production autonome 3.2

Produisez le nuage budget-ventes et décrivez sa direction, sa forme, sa dispersion et une limite.

Auto-vérification

- Mes axes nomment les variables et les dollars.
- J'ai décrit les points avant de citer la corrélation.
- Je n'ai pas transformé la corrélation en preuve causale.