

Capsule 4 - Ajuster le modèle avec R

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

Comment retrouver la droite à partir du fichier CSV?

Le calcul doit pouvoir être repris dans un projet R, du fichier de données aux coefficients interprétés.

Objectifs de la capsule

- Ajuster la droite avec `lm()`.
- Lire les coefficients dans R.
- Présenter une estimation avec son incertitude.
- Formuler H_0 et interpréter une valeur p .

Le projet R

Projet : regression-marketing

```
1 library(tidyverse)
2
3 campagnes <- read_csv(
4   "data/campagnes_marketing_quebec.csv",
5   show_col_types = FALSE
6 )
7
8 colSums(is.na(campagnes[c("ventes", "budget_marketing")]))
```

60 lignes, aucune valeur manquante dans les deux variables du modèle.

L'ajustement avec lm()

```
1 modele <- lm(ventes ~ budget_marketing, data = campagnes)
```

À GAUCHE DE ~

La réponse : ventes

À DROITE DE ~

La variable explicative : budget_marketing

La commande conserve le modèle dans l'objet `modele`.

Les coefficients calculés

```
1 coef(modele)
```



```
(Intercept) budget_marketing  
29922.107      13.582
```

(Intercept) : ordonnée à l'origine. budget_marketing : pente.

La droite estimée : ventes prédites = 29 922,11 + 13,58 × budget.

L'interprétation dans les bonnes unités

```
1 coef(modele)[["budget_marketing"]] * 1000
```



```
[1] 13582
```

Une différence de 1 000 \$ de budget est associée à environ 13 582 \$ de ventes moyennes supplémentaires selon le modèle.

L'incertitude sur la pente

```
1 confint(modele, "budget_marketing", level = 0.95)
```

	2.5 %	97.5 %
budget_marketing	11.93333	15.23067

Intervalle de confiance classique à 95 % : de 11,93 à 15,23 \$ de ventes par dollar de budget.

Pour 1 000 \$ de budget, multipliez aussi les deux bornes par 1 000 : de 11 933 à 15 231 \$ de ventes moyennes supplémentaires.

Les hypothèses restent à examiner

Relation moyenne linéaire, erreurs indépendantes, dispersion constante.

Ici, les mêmes régions reviennent chaque mois. Les résidus et le contexte doivent être examinés avant de faire confiance aux intervalles.

Poser la question du test

$$H_0 : \beta_1 = 0 \quad H_1 : \beta_1 \neq 0$$

H_0 est l'hypothèse nulle : la pente de population est nulle.

Le test porte sur une association linéaire dans le modèle. Il ne démontre pas un effet causal du budget.

Lire la ligne de la pente

```
1 summary(modele)$coefficients["budget_marketing", ]
```

	Estimate	Std. Error	t value	Pr(> t)
	1.358200e+01	8.236280e-01	1.649046e+01	1.458098e-23

Estimate : pente estimée. Std. Error : erreur-type. t value : statistique du test. Pr(>|t|) : valeur p bilatérale.

$$t = \frac{\hat{\beta}_1 - 0}{SE(\hat{\beta}_1)}$$

Que signifie la valeur p?

Sous H_0 et les hypothèses du modèle, la valeur p est la probabilité d'obtenir une statistique au moins aussi extrême que celle observée.

Pour ce test bilatéral, « aussi extrême » signifie aussi loin de zéro, dans l'un ou l'autre sens.

Une petite valeur p indique une moins bonne compatibilité des données avec H_0 . Ce n'est pas la probabilité que H_0 soit vraie.

Décider sous des hypothèses

- Au seuil fixé $\alpha = 0,05$, on rejette H_0 si $p \leq 0,05$.
- Sinon, on ne rejette pas H_0 : on n'a pas prouvé que la pente est nulle.
- Ici, $p < 0,001$; le calcul suppose les hypothèses classiques valides.

La valeur p ne mesure ni l'ampleur de l'association ni son importance pratique. Il faut aussi lire la pente, son intervalle et les diagnostics.

À retenir

1

Un modèle reproductible

2

Des coefficients interprétés

3

Une incertitude sous hypothèses

Production autonome 3.4

Ajustez la droite. Présentez la pente pour 1 000 \$ et son intervalle classique. Formulez H_0 sur la pente et interprétez la valeur p sous les hypothèses du modèle.

Auto-vérification

- La formule place les ventes à gauche de $\sim$.
- Mes valeurs correspondent à `coef(modele)` et `confint(modele)`.
- J'ai indiqué une hypothèse ou une limite à vérifier.