

Capsule 5 - Diagnostiquer avec les résidus

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

La droite se trompe-t-elle de la même façon partout?

Une tendance globale peut masquer des écarts réguliers selon la région. Les résidus permettent de les examiner.

Objectifs de la capsule

- Calculer les résidus et comprendre leur signe.
- Lire un graphique de diagnostic.
- Examiner les écarts selon la région.

Du modèle aux résidus

```
1 resultats <- campagnes |>
2   mutate(
3     ventes_predites = fitted(modele),
4     residu = residuals(modele)
5   )
```


RÉSIDU POSITIF

Ventes observées au-dessus de la droite : sous-estimation.

RÉSIDU NÉGATIF

Ventes observées sous la droite : surestimation.

Les résidus selon les ventes prédites



Les signes à rechercher

COURBURE

La moyenne pourrait être mal décrite par une droite.

ÉVENTAIL

La dispersion pourrait varier avec le niveau des ventes.

Un point isolé appelle une vérification. Son influence ne se déduit pas du seul résidu.

La moyenne des résidus par région

Région	Résidu moyen (\$)
Capitale-Nationale	5676
Estrie	-3340
Mauricie	-226
Montréal	2956
Outaouais	-5066

Capitale-Nationale : sous-estimation moyenne. Outaouais : surestimation moyenne.

Le code du diagnostic par région

```
1 resultats |>
2   group_by(region) |>
3   summarise(
4     observations = n(),
5     residu_moyen = mean(residu),
6     .groups = "drop"
7   )
```

Le graphique résidus-valeurs prédites et ce tableau répondent à des questions complémentaires.

Résultats du diagnostic

La droite décrit la tendance globale, mais les écarts régionaux méritent une analyse complémentaire.

Les mêmes régions sont observées sur plusieurs mois. Ce graphique seul ne vérifie pas l'indépendance des erreurs.

À retenir

1

Un résidu signé

2

Des motifs à rechercher

3

Un contexte à vérifier

Production autonome 3.5

Produisez le graphique des résidus et le tableau par région. Rédigez un constat sur chacun, puis une limite.

Auto-vérification

- Mes axes indiquent les dollars.
- J'ai relié le signe des résidus à une sous-estimation ou une surestimation.
- Je n'ai pas déclaré le modèle valide sur la seule moyenne nulle des résidus.