

Module 03 - Régression linéaire

MQT-2101 - Analyse et modélisation des données

Objectifs du module

- Lire une relation entre deux variables quantitatives.
- Distinguer corrélation, association, prédiction et causalité.
- Ajuster une régression linéaire simple avec `lm()`.
- Interpréter une pente, une ordonnée à l'origine et un R^2 .
- Vérifier les résidus avant de conclure.
- Rédiger une interprétation utile pour une décision d'affaires.

Point de départ

L'ancien matériel introduisait la corrélation, les moindres carrés, les tests, les diagnostics et les exercices R.

La version actuelle conserve ces idées, mais les réorganise autour d'une question appliquée : comment quantifier l'association moyenne entre budget marketing et ventes?

Données du module

```
# A tibble: 6 × 10
  mois      mois_label region canal saison budget_marketing visites_site rabais
<date>    <chr>      <chr> <chr> <chr>      <dbl>      <dbl> <dbl>
1 2025-01-01 janvier    Capit... Info... moyen...    5814    6393    0
2 2025-01-01 janvier    Estrie Info... moyen...    3775    5235  0.15
3 2025-01-01 janvier    Mauri... Rech... moyen...    5497    6880  0.13
4 2025-01-01 janvier    Montr... Rése... moyen...    6215    8106  0.17
5 2025-01-01 janvier    Outao... Rech... moyen...    5703    7107  0.17
6 2025-02-01 février    Capit... Info... moyen...    3246    4958  0.13
# i 2 more variables: ventes <dbl>, satisfaction <dbl>
```

Unité d'observation

- Une ligne représente une combinaison mois-région.
- `ventes` est la variable réponse.
- `budget_marketing` est la variable explicative principale.
- `region`, `canal`, `saison`, `visites_site` et `rabais` contextualisent l'analyse.

Corrélation

La corrélation mesure la force et la direction d'une relation linéaire entre deux variables quantitatives.


Elle est symétrique : la corrélation entre x et y est la même que celle entre y et x . Une régression, elle, impose une variable réponse et une variable explicative.

7

Corrélation dans les données

```
# A tibble: 1 × 1
  correlation_budget_ventes
  <dbl>
1 0.908
```

Nuage de points



Pourquoi un modèle?

- Le graphique montre une tendance.
- Le modèle quantifie cette tendance.
- Le coefficient donne une interprétation moyenne.
- Les résidus montrent ce que la droite ne capture pas.

Modèle linéaire simple

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Dans le module :

- Y_i : ventes observées.
- x_i : budget marketing.
- β_0 : ventes moyennes estimées lorsque le budget vaut 0.
- β_1 : variation moyenne des ventes pour une unité de budget.
- ε_i : écart entre la valeur observée et la droite.

Estimation

La droite de régression est estimée par la méthode des moindres carrés.

Elle choisit les coefficients qui minimisent la somme des carrés des résidus. C'est le principe central repris de l'ancien support de régression.

Ajustement dans R

```
Call:
lm(formula = ventes ~ budget_marketing, data = campagnes)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-16277.1  -6353.5   -347.8   6892.4  17632.8
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.992e+04  4.632e+03   6.46 2.35e-08 ***
budget_marketing 1.358e+01  8.236e-01  16.49 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 8339 on 58 degrees of freedom
Multiple R-squared:  0.8242,    Adjusted R-squared:  0.8212
F-statistic: 271.9 on 1 and 58 DF,  p-value: < 2.2e-16
```

Lire les coefficients

(Intercept)	budget_marketing
29922.107	13.582

La pente est souvent plus utile si on la reformule pour 1 000 dollars de budget.

budget_marketing
13582

Interprétation de la pente

Dans ces données, 1 000 dollars de budget marketing supplémentaire sont associés à une variation moyenne estimée des ventes de $1.3582^{\{4\}}$ dollars.

Cette phrase décrit une association moyenne. Elle ne prouve pas que le budget cause directement les ventes.

Qualité d'ajustement

```
# A tibble: 1 × 3
  r_carre r_carre_ajuste rmse
  <dbl>    <dbl>    <dbl>
1  0.824      0.821 8199.
```

Valeurs prédites et résidus

```
# A tibble: 8 × 6
```

	region	mois_label	budget_marketing	ventes	ventes_predites	residu
	<chr>	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	Capitale-Nationale	janvier	5814	121915	108888.	13027.
2	Estrie	janvier	3775	93518	81194.	12324.
3	Mauricie	janvier	5497	95109	104582.	-9473.
4	Montréal	janvier	6215	121125	114334.	6791.
5	Outaouais	janvier	5703	108469	107380.	1089.
6	Capitale-Nationale	février	3246	82306	74009.	8297.
7	Estrie	février	4927	95280	96841.	-1561.
8	Mauricie	février	2497	56608	63836.	-7228.

Ce qu'on cherche dans les résidus

- Des points répartis autour de 0.
- Pas de courbe évidente.
- Pas de dispersion qui augmente fortement.
- Pas d'observation isolée qui domine l'interprétation.

Prédire

	fit	lwr	upr
1	84250.11	67245.43	101254.8
2	111414.12	94560.27	128268.0
3	138578.12	121237.71	155918.5

Prédiction et prudence

- Une prédiction est incertaine.
- Elle est plus défendable dans la plage observée.
- Elle dépend du modèle choisi.
- Elle ne remplace pas la connaissance du contexte.

Association ou causalité?

Avertissement

Une régression sur données observationnelles ne suffit pas à établir une relation causale.

Pour parler de causalité, il faudrait discuter du plan d'étude, des variables omises, de la temporalité, des mécanismes et des biais possibles.

Réponse attendue

Les ventes sont positivement associées au budget marketing. La pente indique la variation moyenne estimée des ventes pour une hausse du budget, dans les données observées. Le graphique et les résidus doivent être examinés avant de conclure. L'interprétation reste une association, pas une preuve causale.

Sources et prolongements

- Ancien matériel MQT-2101, séance 03 : corrélation, régression linéaire, moindres carrés, diagnostics et exercices R.
- Documentation R : `stats::lm()` et `predict.lm()`.
- Documentation ggplot2 : `geom_point()` et `geom_smooth()`.