

Capsule 4 - Comparer plusieurs modèles

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UNE COMPARAISON LOYALE

Quel modèle prédit le mieux des observations qu'il n'a pas utilisées pour s'ajuster?

Une erreur calculée sur les données d'entraînement mesure surtout l'ajustement. Une période ou un échantillon test séparé permet une comparaison plus crédible des prédictions.

Objectifs de la capsule

- Comparer plusieurs modèles sur les mêmes données.
- Utiliser un graphique de prédictions.
- Calculer une mesure d'erreur.
- Éviter de choisir automatiquement le modèle le plus complexe.

Trois modèles candidats

```
1 modele_lin <- lm(ventes ~ achalandage, data = entraînement)
2 modele_quad <- lm(
3   ventes ~ achalandage + I(achalandage^2),
4   data = entraînement
5 )
6 modele_log <- lm(ventes ~ log(achalandage), data = entraînement)
```



Critères utiles

- Graphique avec les courbes superposées.
- Résidus sans structure évidente.
- Erreur de prédiction plus faible.
- Interprétation compréhensible pour la décision.

RMSE

La RMSE test résume l'erreur typique sur des observations qui n'ont pas servi à ajuster les modèles. Elle s'exprime ici en dollars de ventes. Plus elle est faible, plus les prédictions hors échantillon sont proches des valeurs observées, pour cette séparation précise.

Résultat hors échantillon

modele	rmse_test
lineaire	11 101 \$
quadratique	8 367 \$
logarithmique	9 436 \$

Piège fréquent

Le modèle quadratique obtient la plus faible RMSE sur cette séparation, environ 8 367 \$. Ce résultat dépend toutefois de l'échantillon test; il doit être lu avec le graphique, les résidus et l'interprétabilité.

À retenir

1

Comparer, c'est croiser plusieurs indices.

2

Un chiffre ne suffit pas.

3

Le meilleur modèle est celui qui résume bien les données et reste interprétable.

Production autonome 4.4

Préparez une grille de comparaison avec trois colonnes : graphique, erreur et interprétation.

Auto-vérification

- Les modèles sont comparés sur les mêmes données test.
- La forme retenue est visible et interprétable.
- La prédiction reste dans la plage observée et son incertitude est indiquée.