

Module 04 - Régression non linéaire et transformations

MQT-2101 - Analyse et modélisation des données

Objectifs du module

- Repérer une relation qui n'est pas bien décrite par une droite.
- Comprendre l'idée de saturation.
- Ajuster un modèle linéaire, quadratique et logarithmique.
- Comparer les modèles avec le graphique, les résidus, le R^2 et la RMSE.
- Interpréter le modèle sur l'échelle originale.
- Éviter l'extrapolation fragile.

Point de départ

L'ancien matériel de la séance 04 présentait plusieurs familles de modèles non linéaires : polynômes, splines, GAM, probit, Tobit, logistique et autres.

Dans ce module, on conserve l'idée centrale : la relation peut être courbée. On se limite volontairement aux transformations simples qui restent interprétables dans une première analyse.

Données du module


```
# A tibble: 6 × 16
  mois      mois_label saison  succursale region surface_m2 capacite_reference
  <date>    <chr>      <chr>    <chr>      <chr>      <dbl>      <dbl>
1 2025-01-01 janvier    moyenne Gatineau Outao...    420      2050
2 2025-01-01 janvier    moyenne Montréal Montr...    590      3300
3 2025-01-01 janvier    moyenne Québec Capit...    465      2450
4 2025-01-01 janvier    moyenne Saguenay Sague...    345      1600
5 2025-01-01 janvier    moyenne Sherbrooke Estrie     385      1850
6 2025-01-01 janvier    moyenne Trois-Rivi... Mauri...    360      1720
# i 9 more variables: campagne_locale <chr>, depenses_marketing <dbl>,
#   achalandage <dbl>, taux_occupation <dbl>, ruptures_stock <dbl>,
#   temps_attente_minutes <dbl>, panier_moyen <dbl>, satisfaction <dbl>,
#   ventes <dbl>
```

Question

Les ventes augmentent-elles avec l'achalandage au même rythme sur toute l'échelle?

Si une succursale approche sa capacité, une personne de plus ne produit pas nécessairement le même gain de ventes qu'à faible achalandage.

Visualiser la forme



Pourquoi une droite peut être insuffisante

- La pente d'une droite est constante.
- La saturation implique une pente qui diminue.
- Un modèle linéaire peut surestimer les ventes aux hauts niveaux.
- Le diagnostic doit partir du graphique, pas seulement du R^2 .

Trois modèles simples

Modèle linéaire

```
Call:
lm(formula = ventes ~ achalandage, data = saturation)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-26761  -6074   1049   4832  24473
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 1.046e+05  3.849e+03  27.17  <2e-16 ***
achalandage 2.501e+01  1.632e+00  15.32  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 9103 on 70 degrees of freedom
Multiple R-squared:  0.7703,    Adjusted R-squared:  0.767
F-statistic: 234.7 on 1 and 70 DF,  p-value: < 2.2e-16
```

Modèle quadratique

Call:
lm(formula = ventes ~ achalandage + I(achalandage^2), data = saturation)

Residuals:

	Min	1Q	Median	3Q	Max
	-18324.8	-5138.9	607.2	4375.5	21575.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.700e+04	1.176e+04	3.998	0.000158	***
achalandage	7.308e+01	9.521e+00	7.675	7.84e-11	***
I(achalandage^2)	-9.220e-03	1.806e-03	-5.104	2.80e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7812 on 69 degrees of freedom
Multiple R-squared: 0.8333, Adjusted R-squared: 0.8284
F-statistic: 172.4 on 2 and 69 DF, p-value: < 2.2e-16

Modèle logarithmique

Call:
lm(formula = ventes ~ log(achalandage), data = saturation)

Residuals:

Min	1Q	Median	3Q	Max
-19872	-5040	525	5036	22578

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-318150	27137	-11.72	<2e-16 ***
log(achalandage)	62362	3528	17.68	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 8126 on 70 degrees of freedom
Multiple R-squared: 0.817, Adjusted R-squared: 0.8143
F-statistic: 312.4 on 1 and 70 DF, p-value: < 2.2e-16

Comparer les modèles


```
# A tibble: 3 × 3
```

	modele <chr>	r_carre <dbl>	erreur_rmse <dbl>
1	Linéaire	0.770	8976.
2	Quadratique	0.833	7647.
3	Logarithmique	0.817	8012.


R^2 et RMSE

- Le R^2 mesure la proportion de variation expliquée.
- La RMSE mesure une erreur typique sur l'échelle de la réponse.
- Un meilleur R^2 ne suffit pas.
- Il faut aussi vérifier les résidus et l'interprétabilité.

Superposer les prédictions



Diagnostic des résidus



Extrapolation

Avertissement

Un modèle non linéaire peut devenir très dangereux hors de la plage observée.

Un polynôme peut monter ou descendre rapidement sans raison d'affaires. Il faut donc limiter les prédictions aux niveaux d'achalandage comparables aux données.

Interprétation d'affaires

Si les ventes augmentent de moins en moins vite à haut achalandage, la décision n'est pas seulement d'attirer plus de clients. Il faut aussi regarder la capacité, les ruptures de stock, le personnel et le temps d'attente.

Ce qui sera repris plus tard

- La régression logistique de l'ancien matériel sera reprise dans le module sur la classification et les résultats binaires.
- Les splines et les GAM sont utiles, mais dépassent le niveau attendu ici.
- Pour ce module, on veut surtout choisir et défendre une transformation simple.

Sources et prolongements

- Ancien matériel MQT-2101, séance 04 : modèles non linéaires, modèles polynomiaux, GAM, RMSE et R^2 .
- Documentation R : `lm()` et `predict.lm()`.
- Documentation ggplot2 : `geom_smooth()`.