

Module 04 - Relations non linéaires et transformations

MQT-2101 - Analyse et modélisation des données

Objectifs du module

- Reconnaître et modéliser une courbure.
- Comparer sur des données mises de côté.
- Interpréter une prédiction et ses limites.
- Justifier le choix dans un rapport reproductible.

Le cas et l'unité d'observation

72

observations mois-succursale

6

succursales fictives

2025

douze mois de suivi

Une ligne décrit un mois dans une succursale. Les données sont simulées; les ventes sont en dollars canadiens.

Garder les derniers mois pour comparer

54

janvier à septembre : apprentissage

18

octobre à décembre : validation


3

formes candidates fixées avant la
comparaison

| Explorer et ajuster sur l'apprentissage. Comparer ensuite sur la validation.

Lire le nuage avant de choisir

Janvier à septembre 2025 : données d'apprentissage



Ce qu'une droite impose

$$\hat{y} = b_0 + b_1 x$$

- Une même hausse de x donne une même hausse prédite.
- Une courbe permet une variation qui dépend du point de départ.
- La dispersion autour de la tendance demeure.

Un taux peut dépasser 100 %

$$\text{Taux d'occupation} = \frac{\text{achalandage}}{\text{capacité de référence}}$$

2 400 visites pour une référence de 2 000 : 1,20, soit 120 %. Ce rapport n'est pas une probabilité.

Ralentissement et plateau

- Ralentissement : la hausse devient plus faible.
- Plateau : la courbe se rapproche d'une limite.
- Un ralentissement observé ne démontre pas un plafond.

Une courbe quadratique peut redescendre. Un logarithme croissant n'a pas de plafond.

Logarithmique et logistique

Ventes

réponse quantitative : module 4

Oui / non

réponse binaire : module 10

Log(x)

transformation d'une explicative positive

Le modèle logarithmique étudié ici prédit des dollars. La régression logistique modélise une probabilité.

Trois formes, une même réponse

On note x l'achalandage en milliers de visites et y les ventes en dollars.

Forme	Moyenne modélisée
Droite	$\beta_0 + \beta_1 x$
Quadratique	$\beta_0 + \beta_1 x + \beta_2 x^2$
Logarithmique	$\beta_0 + \beta_1 \ln(x)$, avec $x > 0$

Courbe en x, modèle linéaire en paramètres

$$Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

Le modèle reste linéaire en ses coefficients : `lm()` convient. Une relation courbée n'exige pas forcément une régression non linéaire en paramètres.

Ajuster la droite et la quadratique

```
1 modele_lin <- lm(ventes ~ achalandage_milliers,  
2                   data = apprentissage)  
3 modele_quad <- lm(  
4   ventes ~ achalandage_milliers + I(achalandage_milliers^2),  
5   data = apprentissage  
6 )
```

`I(x^2)` demande le carré numérique. Conservez aussi le terme x.

Interpréter une variation

Comparaison	Hausse prédite (dollars)
2 000 à 2 100 visites	3 487
3 000 à 3 100 visites	1 763

Pour 100 visites supplémentaires, la hausse prédite dépend du point de départ.

Calculer une différence dans la quadratique

$$\hat{y}(x + h) - \hat{y}(x) = b_1 h + b_2(2xh + h^2)$$

- x et x^2 changent ensemble.
- 100 visites : $h = 0,1$ millier.
- Le point de départ x intervient.


Transformer l'explicative avec un logarithme

```
1 modele_log <- lm(ventes ~ log(achalandage_milliers),  
2                 data = apprentissage)
```

Pour une hausse de 10 % de x : $\Delta \hat{y} = b_1 \ln(1,10)$.

La réponse reste en dollars. Il n'y a pas de transformation inverse de y à effectuer.

Superposer les trois formes



Apprendre, comparer, confirmer

Apprendre

ajuster les coefficients sur janvier à septembre

Comparer

prédire octobre à décembre sans réajuster

Confirmer

prévoir de nouvelles données pour évaluer le choix final

Les mois utilisés pour choisir le modèle deviennent un ensemble de validation; ils ne constituent plus un test final indépendant.

Lire la RMSE

$$\text{RMSE} = \left[n^{-1} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \right]^{1/2}$$

- Racine de la moyenne des erreurs au carré.
- Même unité que la réponse : dollars ici.
- Les grandes erreurs pèsent davantage.

Comparer les résultats


Les RMSE sont exprimées en dollars.

Modèle	R ² apprentissage	RMSE apprentissage	RMSE validation
Linéaire	0,783	8 707	10 155
Quadratique	0,825	7 817	7 237
Logarithmique	0,819	7 940	8 409

Le plus grand R^2 ne suffit pas

- R^2 résume l'ajustement sur l'apprentissage.
- Ajouter x^2 ne peut pas réduire le R^2 sur les mêmes lignes.
- Le R^2 ajusté pénalise les paramètres supplémentaires.
- Aucun des deux ne remplace l'erreur de validation.

Examiner les résidus



Un choix provisoire

La quadratique a la plus faible RMSE de validation : 7 237 \$, contre 10 155 \$ pour la droite.

18 observations seulement, regroupées dans six succursales. Deux achalandages de validation dépassent le maximum d'apprentissage. Le classement peut varier sur une autre période.

Délimiter la plage utile

1 151

minimum d'apprentissage, en visites

3 833

maximum d'apprentissage, en visites

2 500

scénario situé dans cette plage

La validation va de 1 500 à 4 166 visites : deux lignes dépassent 3 833.

Calculer une prédiction

```
1 scenario <- tibble(achalandage_milliers = 2.5)
2 prediction <- predict(modele_quad, newdata = scenario,
3                       interval = "prediction", level = 0.95)
4 as.data.frame(prediction) |>
5   mutate(across(everything(), round))
```


	fit	lwr	upr
1	172373	155866	188880

Lire l'intervalle de prédiction

- `fit` : estimation ponctuelle des ventes.
- `lwr` et `upr` : bornes pour une nouvelle observation.
- Un intervalle de confiance viserait la moyenne.

L'intervalle classique suppose notamment une moyenne bien spécifiée, des erreurs indépendantes, de variance constante et normalement distribuées. Il ne corrige pas une courbe mal choisie.

Des modèles proches peuvent diverger



Cinq éléments dans la conclusion

- Question et variables.
- Forme observée sur l'apprentissage.
- Comparaison chiffrée sur la validation.
- Plage d'utilisation.
- Limite et prochaine vérification.

Un exemple de conclusion

Dans les succursales fictives, la relation ventes-achalandage est croissante et présente une courbure. La quadratique obtient une RMSE de validation d'environ 7 237 \$, contre 10 155 \$ pour la droite. Elle constitue un choix provisoire pour résumer cette relation. L'utilisation doit rester prudente dans la plage de 1 151 à 3 833 visites. Une nouvelle période et les contraintes de service doivent être examinées avant toute décision de capacité.

Relier résultat et décision

Résultat

erreur de validation plus faible

Hypothèse

contraintes possibles de service

Décision

recueillir des données avant d'investir

Une relation descriptive ne chiffre pas l'effet d'augmenter la capacité.

La trace Quarto attendue

- Graphique des 54 observations d'apprentissage.
- Formules et code des trois modèles.
- RMSE, diagnostics et comparaison argumentée.
- Scénario de prédiction et limite d'extrapolation.

Redémarrez R, puis utilisez Render : tous les résultats doivent se recalculer.

Repères bibliographiques

- James, Witten, Hastie et Tibshirani (2021), ISLR, 2e éd., chapitres 5 et 7.
- R Core Team, documentation de `lm()` et `predict.lm()`.
- Hyndman et Athanasopoulos (2021), Forecasting: Principles and Practice, section 5.8.

Lectures et liens du module