

Capsule 2 - Préparer les données et le diagnostic minimal

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Nommer l'unité d'observation.
- Identifier les types de variables.
- Repérer les valeurs manquantes.
- Documenter les limites de préparation.

Unité d'observation

Une ligne représente quoi? Une journée, une succursale, une campagne, une combinaison mois-région? Cette réponse guide toute l'interprétation.

Types de variables

- Numérique continue : ventes, budget, achalandage.
- Catégorielle : région, canal, saison.
- Date ou période : mois, semaine, jour.
- Code : parfois numérique, mais pas une quantité.

Diagnostic minimal en R

```
1 library(tidyverse)
2
3 donnees |>
4   summarise(across(everything(), ~ sum(is.na(.x))))
```



Pourquoi c'est important?

Une valeur manquante, une variable mal typée ou une mauvaise unité d'observation peut rendre une conclusion correcte en apparence, mais fragile en réalité.

Phrase utile

Chaque ligne représente [unité]. Les variables centrales sont [réponse] et [explicative]. Les valeurs manquantes touchent surtout [variable], ce qui limite [aspect].

Activité 5.2

Préparez une phrase de diagnostic minimal pour un fichier du module 02, 03 ou 04.

À retenir

- Un diagnostic court vaut mieux qu'une analyse aveugle.
- L'unité d'observation est la base de l'interprétation.
- Les limites doivent apparaître avant la conclusion.