

Capsule 5 - Choisir entre deux modèles

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UN CHOIX SOUS CONTRAINTE

Le modèle le plus complexe reste-t-il le meilleur lorsqu'il doit prévoir de nouvelles observations?

Les modèles doivent être comparés sur la même cible et les mêmes données test. L'erreur hors échantillon, la forme et l'interprétabilité répondent à des questions complémentaires.

Objectifs de la capsule

- Comparer deux modèles avec plusieurs critères.
- Justifier un choix sans se limiter au R^2 .
- Nommer la limite d'extrapolation.
- Communiquer le choix simplement.

Quand comparer?

On compare des modèles lorsque plusieurs formes peuvent répondre à la question : une droite, une courbe quadratique, un logarithme ou un modèle enrichi.

Critères

- Graphique : la forme suit-elle les données?
- Erreur hors échantillon : les prédictions sont-elles proches sur les mêmes données test?
- Résidus : reste-t-il une structure?
- Interprétation : le modèle est-il défendable?
- Prudence : le modèle extrapole-t-il trop?

Phrase utile

Sur la séparation utilisée au module 04, le modèle quadratique obtient une RMSE test d'environ 8 367 \$, contre 11 101 \$ pour la droite. Il décrit mieux la courbure observée, mais son utilisation doit rester limitée à la plage d'achalandage représentée dans les données.

Erreur fréquente

Comparer une erreur d'entraînement d'un modèle à une erreur test d'un autre, ou choisir le modèle le plus complexe sans expliquer son apport réel à la question.

Réponse attendue

- Nommer les deux modèles.
- Donner un critère visuel.
- Donner un critère numérique ou diagnostique.
- Conclure en fonction de la décision.
- Ajouter une limite.

À retenir

1

Comparer un modèle, c'est justifier un choix.

2

Un bon choix est à la fois statistique et interprétable.

3

L'extrapolation est une limite majeure.

Production autonome 5.5

Rédigez une justification de modèle en cinq phrases maximum à partir du module 04.

Auto-vérification

- La méthode répond au verbe de la question.
- Le résultat, le diagnostic et les unités sont présents.
- La conclusion distingue description, prédiction et causalité.