Synthèse - Résultats binaires et classification

MQT-2101 - Analyse et modélisation des données

Une décision à partir d’un risque

Que savons-nous avant d’agir et quelles erreurs pouvons-nous accepter?

Cible, unité et séparation

- Un résultat binaire décrit un événement observable avec une classe positive définie.
- La décision précède la réalisation de la cible : chaque prédicteur doit être disponible à cette origine.
- Séparer l’apprentissage, qui estime les coefficients, la validation, qui choisit une règle, et le test, qui l’évalue après fixation.

Logistique, cotes et probabilités

- Pour une probabilité p, la cote vaut p/(1-p).
- La régression logistique pose la formule logistique et transforme ce prédicteur en probabilité comprise entre 0 et 1.
- Pour une unité supplémentaire de x, à autres variables fixées, les cotes sont multipliées par exp(β1).

Matrice et mesures

- Les vrais positifs VP sont les événements ciblés; les faux négatifs FN sont les événements manqués.
- Les faux positifs FP sont des non-événements ciblés et les vrais négatifs VN les non-événements écartés.
- Sensibilité = VP/(VP+FN), spécificité = VN/(VN+FP), précision = VP/(VP+FP), exactitude = (VP+VN)/N.

Seuil, coût et capacité

- Le seuil transforme une probabilité en classe.
- Abaisser le seuil ne diminue pas le nombre de personnes ciblées ni le nombre de vrais positifs pour des scores fixés; la précision peut augmenter ou diminuer.
- Les coûts fictifs ou la capacité guident la règle.

Calibration et action

- Une calibration descriptive compare, par groupes de risques prédits, la probabilité moyenne à la fréquence observée.
- Les groupes peuvent être petits et les résultats incertains.
- Le score de Brier résume l’erreur quadratique des probabilités mais ne mesure pas uniquement la calibration.

À retenir

- Une probabilité ne suffit pas à fixer une action.
- Le seuil se choisit en validation et s’évalue sur un test distinct.
- Le risque prédit n’est pas l’effet causal d’un contact.

Références et crédits

James, Witten, Hastie et Tibshirani (2021), *An Introduction to Statistical Learning*, 2e édition.

Données fictives du cours MQT-2101, Université Laval.