

Capsule 3 - Typologie des données

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UNE DÉCISION CONCRÈTE

Quelle est la « moyenne » du jour de la semaine?

Un logiciel répondra sans broncher : 3,98. La réponse est exacte... et n'a aucun sens, parce que le jour de la semaine n'est pas une quantité. Reconnaître le type d'une variable évite ce genre de calcul juste mais absurde.

Objectifs de la capsule

- Comprendre ce que représente une observation.
- Distinguer les principaux types de variables.
- Reconnaître un code numérique qui n'est pas une quantité.

Observation, variable, unité

OBSERVATION

L'unité décrite par une ligne : une journée, une transaction, une succursale, une personne.

VARIABLE

Une caractéristique mesurée ou codée : nombre, catégorie, date, statut, code.

Avant toute moyenne ou tout graphique, il faut savoir ce que chaque colonne mesure et ce qu'une ligne représente.

La base birth_us.csv

Une ligne correspond à une journée d'observation. Voir  [birth_us.csv](#).

year

année

month

mois

date_of_month

jour du mois

day_of_week

jour codé de 1 à 7

births

naissances

Variables numériques

Une variable numérique représente une quantité mesurable ou comptable.

- on peut calculer un minimum, une moyenne, une médiane;
- l'unité de mesure doit être claire;
- continue (une mesure) ou discrète (un dénombrement).

`births` est numérique **discrète** : elle compte les naissances d'une journée.

Variables catégorielles : nominal et ordinal

NOMINAL

Des groupes sans ordre : jour de la semaine, succursale, région.

ORDINAL

Des modalités ordonnées : satisfaction 1 à 5, niveau de risque faible/moyen/élevé.

On compte des effectifs ou des proportions ; pour l'ordinal, l'ordre porte de l'information.

Quand un nombre n'est pas une quantité

Un code numérique peut ressembler à un nombre sans être une quantité.

Dans `birth_us.csv`, `day_of_week` utilise 1 à 7. Ces nombres identifient des jours : leur moyenne n'a pas de sens.

Un code doit souvent être converti en catégorie avant d'être résumé ou visualisé.

Premiers signaux de qualité

Avant l'analyse, repérer ce qui peut modifier l'interprétation.

- valeurs manquantes;
- valeurs impossibles ou inattendues;
- changements de codage ou unités mélangées;
- libellés ambigus.

À retenir

1

Une ligne s'interprète toujours comme une unité d'analyse.

2

Le type d'une variable détermine les résumés et graphiques possibles.

3

Un code numérique n'est pas automatiquement une quantité.

Production autonome 1.3

Classez les variables de `birth_us.csv` dans un court tableau.

Pour chaque variable : nom, type, rôle possible dans une analyse, précaution d'interprétation.