

Capsule 4 - Préparation des données

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UNE DÉCISION CONCRÈTE

Que vaut une analyse juste menée sur des données mal préparées?

Elle donne un résultat faux, mais présenté avec assurance. Trois colonnes de date qu'on ne peut pas trier, un code qu'on moyenne par erreur : la préparation rend les données dignes de confiance avant tout calcul.

Objectifs de la capsule

- Comprendre pourquoi une base se prépare avant d'être résumée.
- Créer une vraie date et transformer un code en catégorie.
- Documenter les transformations pour les rendre reproductibles.

Point de départ : birth_us.csv

Une ligne correspond à une journée. Voir  birth_us.csv.

year

morceau de date

month

morceau de date

date_of_month

morceau de date

day_of_week

code de jour

births

naissances/jour

Préparer sans modifier au hasard

Une transformation répond toujours à un besoin d'analyse.

- garder la variable d'origine pour vérifier;
- créer une nouvelle variable quand le sens devient plus clair;
- nommer et pouvoir expliquer ce qui a changé.

Deux transformations utiles

CRÉER UNE DATE

`year` + `month` + `date_of_month` → `2000-01-01`. La journée devient un repère temporel complet : trier, situer, construire une série.

CODER EN CATÉGORIE

`day_of_week` (1 à 7) → lundi ... dimanche. Le jour devient une catégorie lisible plutôt qu'un nombre à moyenner.

Le geste en R

```
1 birth <- birth |>
2   mutate(
3     date = make_date(year, month, date_of_month),
4     jour_semaine = factor(
5       day_of_week, levels = 1:7,
6       labels = c("lundi", "mardi", "mercredi", "jeudi",
7                 "vendredi", "samedi", "dimanche")
8     )
9   )
```

La version complète et commentée est montrée dans la [démonstration 1](#).

Vérifier avant de résumer

Vérification	Pourquoi
Valeurs manquantes dans <code>births</code>	éviter un résumé calculé sur une information absente
Codes hors de 1–7, mois hors de 1–12	repérer un codage impossible
Une seule ligne par date	éviter les doublons avant de moyenner

Cette vérification ne remplace pas un nettoyage complet : elle signale les points à examiner.

Documenter les transformations

- `date` : créée avec `year`, `month`, `date_of_month`;
- `jour_semaine` : créée à partir de `day_of_week`;
- `births` : conservée comme nombre quotidien;
- variables d'origine gardées pour vérification.

Ce recodage de `jour_semaine` servira dès la capsule 6 à révéler un écart frappant entre la semaine et le week-end.

À retenir

1

Préparer une base, c'est clarifier le sens des variables.

2

Une date complète vaut mieux que trois morceaux de date.

3

Toute transformation doit pouvoir être expliquée et reproduite.

Production autonome 1.4

Préparez mentalement la base avant de résumer `births`.

Indiquez ce que représente une ligne de `birth_us.csv`, pourquoi `day_of_week` doit être traité comme une catégorie, et une vérification à faire avant un résumé.

Auto-vérification : votre réponse est complète si elle relie une ligne à une journée, transforme le code de jour en catégorie lisible et nomme au moins une vérification concrète, par exemple les valeurs manquantes ou les codes inattendus.