

Capsule 4 - Préparation des données

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Comprendre pourquoi une base doit être préparée avant d'être résumée.
- Créer une vraie date à partir de colonnes séparées.
- Transformer un code numérique en catégorie lisible.
- Documenter les transformations utiles à l'analyse.

Pourquoi préparer la base?

Une base peut être lisible pour un humain sans être directement prête pour l'analyse.

La préparation consiste à rendre explicites les formats, les unités et les codes pour éviter des calculs corrects sur des variables mal interprétées.

Point de départ : birth_us.csv

Dans cette base, une ligne correspond à une journée d'observation.

Variable	Rôle avant préparation
year	morceau de date
month	morceau de date
date_of_month	morceau de date
day_of_week	code de jour
births	nombre de naissances

Préparer sans modifier au hasard

Une transformation doit toujours répondre à un besoin d'analyse.

- garder la variable originale si elle est utile pour vérifier;
- créer une nouvelle variable quand le sens devient plus clair;
- nommer la transformation;
- pouvoir expliquer ce qui a changé.

Vérifier les noms et la structure

Avant de transformer, il faut lire la structure de la base et vérifier le sens des colonnes.

Variable	Question à se poser
<code>year</code>	Est-ce bien l'année de la journée observée?
<code>month</code>	Est-ce bien le mois, codé de 1 à 12?
<code>date_of_month</code>	Est-ce bien le jour dans le mois?
<code>day_of_week</code>	Est-ce un code ou une quantité?
<code>births</code>	Est-ce un nombre quotidien de naissances?

La question n'est pas seulement : est-ce que la base est ouverte? Il faut aussi vérifier ce que chaque colonne représente.

Créer une vraie date

Les colonnes `year`, `month` et `date_of_month` décrivent ensemble une date.

Avant	Après	Gain d'interprétation
<code>year = 2000, month = 1,</code> <code>date_of_month = 1</code>	<code>2000-01-01</code>	la journée devient un repère temporel complet

Une vraie date permet de trier les observations, de construire une série chronologique et de vérifier les périodes couvertes.

Transformer un code en catégorie

`day_of_week` contient des nombres, mais ces nombres identifient des jours.

Code	Libellé
1	lundi
2	mardi
3	mercredi
4	jeudi
5	vendredi
6	samedi
7	dimanche

Après cette transformation, le jour de la semaine devient une catégorie interprétable plutôt qu'un nombre à moyenner.

Valeurs manquantes et inattendues

Une première vérification cherche les valeurs absentes ou impossibles.

Vérification	Pourquoi?
Valeurs manquantes dans <code>births</code>	éviter un résumé calculé sur une information absente
Codes de jour hors de 1 à 7	repérer un codage impossible
Mois hors de 1 à 12	repérer une date impossible

Cette vérification ne remplace pas un nettoyage complet. Elle signale les points à examiner avant de produire des résumés.

Cohérence temporelle et doublons

Une base quotidienne devrait avoir une seule observation par date.

Vérification	Question
Une seule ligne par date	Est-ce que chaque journée apparaît une seule fois?
Période couverte	Est-ce que le début et la fin de la base sont cohérents?
Ordre temporel	Est-ce que les journées peuvent être replacées dans l'ordre?
Si une date apparaît deux fois, il faut comprendre pourquoi avant de calculer une moyenne ou de produire une série temporelle.	

Documenter les transformations

- `date` : créée avec `year`, `month` et `date_of_month`;
- `jour_semaine` : créée à partir du code `day_of_week`;
- `births` : conservée comme nombre de naissances quotidiennes;
- les variables originales restent disponibles pour vérification.

Une transformation documentée peut être relue, corrigée et reproduite.

Résumé des transformations

La préparation nécessaire ici reste minimale : créer une date complète, transformer le code de jour en catégorie et documenter ces choix.

Transformation	But
<code>year + month + date_of_month</code> → <code>date</code>	situer les observations dans le temps
<code>day_of_week</code> → <code>jour_semaine</code>	comparer des catégories lisibles
conserver <code>births</code>	garder le nombre quotidien de naissances

Ce que la préparation permet

1

Situer chaque observation dans le temps.

2

Comparer les jours comme des catégories.

3

Produire des résumés plus faciles à interpréter.

À retenir

- Préparer une base, c'est clarifier le sens des variables.
- Une date complète est plus utile que trois morceaux de date.
- Un code numérique peut représenter une catégorie.
- Toute transformation doit pouvoir être expliquée.

Production autonome 1.4

Préparez mentalement la base avant de résumer `births`.

Indiquez ce que représente une ligne de `birth_us.csv`, expliquez pourquoi `day_of_week` doit être traité comme une catégorie et nommez une vérification à faire avant de produire un résumé descriptif.

Auto-vérification : votre réponse est complète si elle relie une ligne à une journée, transforme le code de jour en catégorie lisible et nomme au moins une vérification concrète, par exemple les valeurs manquantes ou les codes inattendus.