

Capsule 4 - Préparation des données

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Comprendre pourquoi une base doit être préparée avant d'être résumée.
- Créer une vraie date à partir de colonnes séparées.
- Transformer un code numérique en catégorie lisible.
- Documenter les transformations utiles à l'analyse.

Pourquoi préparer la base?

Une base peut être lisible pour un humain sans être directement prête pour l'analyse.

La préparation consiste à rendre explicites les formats, les unités et les codes pour éviter des calculs corrects sur des variables mal interprétées.

Point de départ : `birth_us.csv`

Dans cette base, une ligne correspond à une journée d'observation.

Variable	Rôle avant préparation
<code>year</code>	morceau de date
<code>month</code>	morceau de date
<code>date_of_month</code>	morceau de date
<code>day_of_week</code>	code de jour
<code>births</code>	nombre de naissances

Préparer sans modifier au hasard

Une transformation doit toujours répondre à un besoin d'analyse.

- garder la variable originale si elle est utile pour vérifier;
- créer une nouvelle variable quand le sens devient plus clair;
- nommer la transformation;
- pouvoir expliquer ce qui a changé.

Vérifier les noms et la structure

Avant de transformer, il faut lire la structure de la base.

```
1 library(tidyverse)
2 library(lubridate)
3
4 birth_us <- read_csv("modules/semaine-01-introduction/data/birth_us.csv")
5
6 glimpse(birth_us)
```

La question n'est pas seulement : est-ce que R a lu le fichier? Il faut aussi vérifier ce que chaque colonne représente.

Créer une vraie date

Les colonnes `year`, `month` et `date_of_month` décrivent ensemble une date.

```
1 birth_prepare <- birth_us |>
2   mutate(
3     date = make_date(year, month, date_of_month)
4   )
```

Une vraie date permet de trier les observations, de construire une série chronologique et de vérifier les périodes couvertes.

Transformer un code en catégorie

`day_of_week` contient des nombres, mais ces nombres identifient des jours.

```
1 birth_prepare <- birth_prepare |>
2   mutate(
3     jour_semaine = factor(
4       day_of_week,
5       levels = 1:7,
6       labels = c(
7         "lundi", "mardi", "mercredi", "jeudi",
8         "vendredi", "samedi", "dimanche"
9       )
10    )
11  )
```

Après cette transformation, le jour de la semaine devient une catégorie interprétable plutôt qu'un nombre à moyenner.

Valeurs manquantes et inattendues

Une première vérification cherche les valeurs absentes ou impossibles.

```
1 birth_prepare |>
2   summarise(
3     valeurs_manquantes = sum(is.na(births)),
4     jours_codes_inattendus = sum(!day_of_week %in% 1:7)
5   )
```

Cette vérification ne remplace pas un nettoyage complet. Elle signale les points à examiner avant de produire des résumés.

Cohérence temporelle et doublons

Une base quotidienne devrait avoir une seule observation par date.

```
1 birth_prepare |>  
2   count(date) |>  
3   filter(n > 1)
```



Si une date apparaît deux fois, il faut comprendre pourquoi avant de calculer une moyenne ou de produire une série temporelle.

Documenter les transformations

- `date` : créée avec `year`, `month` et `date_of_month`;
- `jour_semaine` : créée à partir du code `day_of_week`;
- `births` : conservée comme nombre de naissances quotidiennes;
- les variables originales restent disponibles pour vérification.

Une transformation documentée peut être relue, corrigée et reproduite.

Code R minimal

```
1 birth_prepare <- birth_us |>
2   mutate(
3     date = make_date(year, month, date_of_month),
4     jour_semaine = factor(
5       day_of_week,
6       levels = 1:7,
7       labels = c(
8         "lundi", "mardi", "mercredi", "jeudi",
9         "vendredi", "samedi", "dimanche"
10      )
11   )
12 )
```

Ce code prépare seulement ce qui est nécessaire pour la suite immédiate : résumer les naissances et comparer les jours de la semaine.

Ce que la préparation permet

1

Situer chaque observation dans le temps.

2

Comparer les jours comme des catégories.

3

Produire des résumés plus faciles à interpréter.

À retenir

- Préparer une base, c'est clarifier le sens des variables.
- Une date complète est plus utile que trois morceaux de date.
- Un code numérique peut représenter une catégorie.
- Toute transformation doit pouvoir être expliquée.

Production autonome 1.4

Préparez mentalement la base avant de résumer `births`.

Indiquez ce que représente une ligne de `birth_us.csv`, expliquez pourquoi `day_of_week` doit être traité comme une catégorie et nommez une vérification à faire avant de produire un résumé descriptif.

Auto-vérification : votre réponse est complète si elle relie une ligne à une journée, transforme le code de jour en catégorie lisible et nomme au moins une vérification concrète, par exemple les valeurs manquantes ou les codes inattendus.