

Capsule 6 - Comparer prudemment

MQT-2101 - Analyse et modélisation des données

Objectifs de la capsule

- Comparer une variable numérique selon une variable catégorielle.
- Lire un graphique de comparaison sans expliquer trop vite.
- Distinguer un nombre brut d'un indicateur ajusté à l'échelle.
- Formuler une limite d'interprétation claire.

Pourquoi comparer?

Après avoir décrit une variable seule, on veut souvent savoir si elle varie selon un groupe, une période ou une autre caractéristique.

Comparer sert à décrire des écarts observés. Cela ne suffit pas à expliquer leurs causes.

Deux situations de comparaison

Situation	Question descriptive
<code>births</code> selon <code>jour_semaine</code>	Les distributions se ressemblent-elles selon les jours?
<code>incidents_00_14</code> selon l'exposition	Le nombre brut raconte-t-il la même chose qu'un taux?
Dans les deux cas, il faut nommer l'échelle utilisée avant de conclure.	

Comparer `births` selon `jour_semaine`

On compare une variable numérique avec une variable catégorielle.

- variable numérique : `births`;
- variable catégorielle : `jour_semaine`;
- unité d'observation : une journée;
- objectif : décrire les écarts entre distributions.

Numérique + catégorie : boxplot

Un boxplot résume la distribution d'une variable numérique dans chaque groupe.

centre

médiane du groupe

étendue

dispersion visible

écarts

comparaison entre groupes

Code R minimal

```
1 birth_prepare |>
2   filter(!is.na(jour_semaine)) |>
3   ggplot(aes(jour_semaine, births)) +
4   geom_boxplot(fill = "#E9C46A", color = "#1F2933") +
5   labs(
6     title = "Naissances selon le jour de la semaine",
7     x = NULL,
8     y = "Nombre de naissances"
9   ) +
10  theme_minimal(base_size = 12)
```

Lire les écarts

Le graphique peut montrer que certains jours ont des niveaux plus élevés ou plus faibles.

Une différence visible décrit un écart dans la base. Elle ne dit pas encore pourquoi cet écart existe.

Nombre brut et échelle

Dans `safety_airlines.csv`, les compagnies n'ont pas toutes la même taille ni la même exposition.

Indicateur	Ce qu'il mesure
<code>incidents_00_14</code>	nombre brut d'incidents
<code>avail_seat_km_per_week</code>	volume d'activité hebdomadaire
<code>incidents_par_milliard</code>	incidents par milliard de sièges-kilomètres estimés

Pourquoi un taux indicatif?

Deux compagnies peuvent avoir des nombres bruts différents simplement parce qu'elles n'ont pas le même volume d'activité.

Un taux indicatif ramène les incidents à une échelle commune. Il facilite la comparaison, mais il dépend aussi de la manière dont l'exposition est calculée.

Code R minimal

```
1 safety_resume <- safety_airlines |>
2   mutate(
3     exposition_00_14_milliards =
4       avail_seat_km_per_week * 52 * 15 / 1e9,
5     incidents_par_milliard =
6       incidents_00_14 / exposition_00_14_milliards
7   )
```

Ce taux est un indicateur descriptif pour comparer l'ordre de grandeur. Il ne constitue pas à lui seul une évaluation complète de la sécurité.

Comparer deux classements

```
1 safety_resume |>
2   select(
3     airline,
4     incidents_00_14,
5     incidents_par_milliard
6   ) |>
7   arrange(desc(incidents_par_milliard))
```

Si le classement change entre le nombre brut et le taux, c'est le signe que l'échelle de comparaison influence l'interprétation.

Association et causalité

Une comparaison descriptive peut révéler une association. Elle ne démontre pas une cause.

- Un boxplot décrit des écarts entre groupes.
- Un taux décrit un indicateur ramené à une échelle commune.
- Une cause demande d'autres informations et une stratégie d'analyse adaptée.

Écrire une limite

Phrase acceptable : le graphique montre des écarts de naissances selon le jour de la semaine, mais il ne permet pas d'expliquer les mécanismes qui produisent ces écarts.

Phrase acceptable : le taux indicatif tient compte d'une exposition approximée, mais il ne résume pas tous les facteurs liés à la sécurité aérienne.

À retenir

- Comparer demande toujours de nommer les variables et l'échelle.
- Un nombre brut peut être utile, mais il peut être trompeur sans contexte.
- Un taux aide à comparer sur une base commune.
- Une comparaison descriptive ne prouve pas une cause.

Production autonome 1.6

Produisez deux constats descriptifs et une limite.

Comparez `births` selon `jour_semaine`, puis comparez `incidents_00_14` au taux indicatif dans `safety_airlines.csv`. Terminez par une limite qui précise ce que ces comparaisons ne permettent pas de conclure.

Auto-vérification : le travail est complet si chaque constat nomme les variables comparées, précise l'échelle utilisée et évite de transformer une comparaison descriptive en conclusion causale.