

Capsule 4 - Importer et inspecter un tableau

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

UNE DÉCISION CONCRÈTE

Comment savoir si R a vraiment lu ce que vous croyez avoir importé?

Un fichier importé sans vérification, c'est un calcul juste sur un tableau mal connu. Avant toute moyenne, il faut savoir combien il y a de lignes, combien il y a de colonnes, quels sont les types de variables et ce que représente une ligne.

Objectifs de la capsule

- Importer un fichier CSV dans R.
- Nettoyer les noms de variables.
- Inspecter les dimensions, les types et l'unité d'observation.

Importer le fichier

```
1 library(tidyverse)
2 library(janitor)
3
4 ventes_operations <- readr::read_csv(
5   "data/ventes_operations_quebec.csv",
6   show_col_types = FALSE
7 ) |>
8   clean_names()
```



Pourquoi `clean_names()` ?

Dans le fichier fourni, les noms sont déjà normalisés : `clean_names()` ne les modifie pas. L'appel reste utile comme vérification reproductible et protège le code si une version future contient des espaces, des majuscules ou des caractères spéciaux.

avant	apres	identique
mois	mois	TRUE
mois_nom	mois_nom	TRUE
succursale	succursale	TRUE
region	region	TRUE
surface_m2	surface_m2	TRUE
campagne_locale	campagne_locale	TRUE
canal_principal	canal_principal	TRUE
clients	clients	TRUE
panier_moyen	panier_moyen	TRUE
ventes	ventes	TRUE
delai_livraison_jours	delai_livraison_jours	TRUE
satisfaction	satisfaction	TRUE

Inspecter avec `glimpse()`

```

Rows: 24
Columns: 12
$ mois           <date> 2025-01-01, 2025-01-01, 2025-01-01, 2025-01-01,...
$ mois_nom       <chr> "janvier", "janvier", "janvier", "janvier", "fév...
$ succursale     <chr> "Montréal", "Québec", "Sherbrooke", "Trois-Riviè...
$ region        <chr> "Montréal", "Capitale-Nationale", "Estrie", "Mau...
$ surface_m2     <dbl> 540, 420, 360, 335, 540, 420, 360, 335, 540, 420...
$ campagne_locale <chr> "non", "oui", "non", "non", "non", "non", "oui",...
$ canal_principal <chr> "magasin", "magasin", "web", "web", "web", "maga...
$ clients        <dbl> 2254, 1858, 1506, 1199, 2162, 1682, 1585, 1458, ...
$ panier_moyen   <dbl> 53.11, 59.40, 63.31, 68.21, 66.53, 55.20, 58.44,...
$ ventes         <dbl> 119710, 110365, 95345, 81784, 143838, 92846, 926...
$ delai_livraison_jours <dbl> 2.2, 3.8, 4.5, 3.5, 3.6, 1.8, 3.5, 2.6, NA, 3.9,...
$ satisfaction   <dbl> 8.3, 8.6, 7.3, 8.1, NA, 7.9, 7.8, 8.0, 7.7, 7.9,...

```

`glimpse()` montre en un coup d'oeil les colonnes, leurs types et quelques valeurs.

Dimensions et unité d'observation

[1] 24 12

Première valeur : le nombre de lignes. Deuxième valeur : le nombre de colonnes. Ici, une ligne correspond à une succursale pour un mois.

Types de variables à repérer

Type	Exemples dans le tableau
Date ou période	mois
Catégorie	succursale, region, canal_principal
Numérique	clients, ventes, delai_livraison_jours, satisfaction
Indicateur	campagne_locale

À retenir

1

Le code d'importation reste dans le `.qmd`.

2

`clean_names()` et `glimpse()` préparent et inspectent.

3

L'unité d'observation se nomme avant toute analyse.

Production autonome 2.4

Importez `ventes_operations_quebec.csv` et décrivez le tableau.

Indiquez : le code d'importation, le nombre de lignes, le nombre de colonnes et ce que représente une ligne.

Auto-vérification

- Le document se rend du début à la fin sans intervention manuelle.
- Les valeurs manquantes et les unités sont signalées.
- Chaque résultat est accompagné d'une phrase d'interprétation.