

Capsule 6 - Conclure sans dépasser les données

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

Quelle conclusion la direction peut-elle utiliser?

La réponse doit quantifier l'association, donner les limites du modèle et préciser l'incertitude d'une prédiction.

Objectifs de la capsule

- Interpréter le coefficient de détermination R^2 .
- Distinguer moyenne estimée et nouvelle observation.
- Rédiger une conclusion appuyée sur les diagnostics.

Le coefficient de détermination

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

Ici : 0,824, soit environ 82,4 % de la variation des ventes décrite par la droite.

| Calcul sur les observations qui ont servi à ajuster le modèle.

Deux sommes de carrés

$$\text{SSE} = \sum_i (y_i - \hat{y}_i)^2 \quad \text{SST} = \sum_i (y_i - \bar{y})^2$$

SSE : SOMME RÉSIDUELLE

Écarts au carré entre les observations et la droite.

SST : SOMME TOTALE

Écarts au carré entre les observations et leur moyenne.

Avec une ordonnée à l'origine : $R^2 = 1 - \text{SSE} / \text{SST}$, si $\text{SST} > 0$.

Passer du rapport au pourcentage

Exemple : SSE = 30 et SST = 120.

$$R^2 = 1 - \frac{30}{120} = 0,75 = 75\%$$

La droite explique 75 % de la variation observée autour de la moyenne. Les 25 % restants correspondent à la variation résiduelle.

0,75 est une proportion; 75 % est le pourcentage correspondant.

Ajustement et diagnostic

82,4 %

Variation décrite dans cet échantillon

Régions

Résidus moyens différents

À vérifier

Performance sur de nouvelles données

Un R^2 élevé ne remplace ni le diagnostic ni une évaluation sur de nouvelles observations.

La plage de prédiction

2 497 \$

Budget minimal observé

6 000 \$

Exemple dans la plage

8 857 \$

Budget maximal observé

Prédire au-delà de cette plage est une extrapolation. Dans la plage, le contexte doit aussi rester comparable.

Le calcul pour 6 000 \$

```
1 nouveau_budget <- tibble(budget_marketing = 6000)
2
3 predict(modele, newdata = nouveau_budget,
4         interval = "prediction", level = 0.95)
```

	fit	lwr	upr
1	111414.1	94560.27	128268

| **fit** : valeur prédite. **lwr** et **upr** : bornes de l'intervalle.

Une prédiction accompagnée de son intervalle

111 414 \$

Ventes prédites pour 6 000 \$ de budget

94 560 \$

Borne inférieure

128 268 \$

Borne supérieure

| Intervalle de prédiction classique à 95 %, sous les hypothèses du modèle.

Moyenne et nouvelle observation

INTERVALLE DE CONFIANCE

Incertitude sur les ventes moyennes pour un budget donné.

INTERVALLE DE PRÉDICTION

Incertitude pour une nouvelle observation, y compris sa dispersion autour de la moyenne.

Pour le même budget et le même niveau, l'intervalle de prédiction est plus large.

Une conclusion appuyée sur les résultats

Pour 1 000 \$ de budget supplémentaire, la droite estime environ 13 582 \$ de ventes moyennes supplémentaires.

Elle décrit 82,4 % de la variation observée. Les résidus moyens varient selon la région. Ces données simulées ne prouvent pas qu'augmenter le budget provoquerait cette hausse des ventes.

Prochaine étape de l'analyse

Examiner les différences régionales et temporelles, puis évaluer les prédictions sur de nouvelles données.

| Une décision sur le budget demande aussi des informations sur les coûts et un plan d'étude adapté.

À retenir

1

Une association quantifiée

2

Une prédiction incertaine

3

Une conclusion avec ses limites

Production autonome 3.6

Rédigez cinq phrases : question, pente pour 1 000 \$, ajustement et diagnostic, limite, prochaine étape.

Auto-vérification

- Je calcule $R^2 = 1 - \text{SSE} / \text{SST}$ et le convertis en pourcentage.
- Le R^2 décrit l'ajustement sur les données utilisées.
- La prédiction indique le budget, l'unité et son intervalle.
- Ma conclusion tient compte des écarts régionaux et de la limite causale.