

Capsule 3 - Ajouter une transformation simple

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

Comment représenter une hausse qui ralentit?

Une droite, une courbe quadratique et un logarithme imposent des formes différentes. Le choix doit rester lisible sur l'échelle des ventes.

Objectifs de la capsule

- Écrire trois modèles candidats.
- Ajuster les modèles avec `lm()`.
- Interpréter une différence de prédictions.

Trois formes, une même réponse

On note x l'achalandage en milliers de visites et y les ventes en dollars.

Forme	Moyenne modélisée
Droite	$\beta_0 + \beta_1 x$
Quadratique	$\beta_0 + \beta_1 x + \beta_2 x^2$
Logarithmique	$\beta_0 + \beta_1 \ln(x)$, avec $x > 0$

Courbe en x, modèle linéaire en paramètres

$$Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

Le modèle reste linéaire en ses coefficients : `lm()` convient. Une relation courbée n'exige pas forcément une régression non linéaire en paramètres.

Fixer les données d'apprentissage

```
1 saturation <- saturation |>
2   mutate(achalandage_milliers = achalandage / 1000)
3 apprentissage <- saturation |>
4   filter(mois < as.Date("2025-10-01"))
5 validation <- saturation |>
6   filter(mois >= as.Date("2025-10-01"))
```



Ajuster la droite et la quadratique

```
1 modele_lin <- lm(ventes ~ achalandage_milliers,  
2                 data = apprentissage)  
3 modele_quad <- lm(  
4   ventes ~ achalandage_milliers + I(achalandage_milliers^2),  
5   data = apprentissage  
6 )
```

`I(x^2)` demande le carré numérique. Conservez aussi le terme x.

Interpréter une variation

Comparaison	Hausse prédite (dollars)
2 000 à 2 100 visites	3 487
3 000 à 3 100 visites	1 763

Pour 100 visites supplémentaires, la hausse prédite dépend du point de départ.

Calculer une différence dans la quadratique

$$\hat{y}(x + h) - \hat{y}(x) = b_1 h + b_2(2xh + h^2)$$

- x et x^2 changent ensemble.
- 100 visites : $h = 0,1$ millier.
- Le point de départ x intervient.


Transformer l'explicative avec un logarithme

```
1 modele_log <- lm(ventes ~ log(achalandage_milliers),  
2                 data = apprentissage)
```

Pour une hausse de 10 % de x : $\Delta \hat{y} = b_1 \ln(1,10)$.

La réponse reste en dollars. Il n'y a pas de transformation inverse de y à effectuer.

Superposer les trois formes



Ce que la forme ne garantit pas

- Quadratique : une courbure, sans plateau imposé.
- Logarithme : défini seulement pour x positif.
- Une meilleure apparence doit être confrontée à la validation.

À retenir

Forme

trois candidats explicites

Échelle

ventes en dollars

Variation

comparer des prédictions

Production autonome 4.3

Ajustez les trois modèles sur janvier à septembre. Avec le modèle quadratique, comparez la hausse prédite de 2 000 à 2 100 visites à celle de 3 000 à 3 100 visites.

Auto-vérification

- J'ai exprimé x en milliers de visites.
- Les trois modèles utilisent les mêmes 54 lignes.
- Je n'interprète pas le coefficient de x comme une pente constante dans le modèle quadratique.