

# Module 05 - Préparation à l'examen intra

MQT-2101 - Analyse et modélisation des données

# Objectifs de la révision

- Mobiliser les modules 01 à 04.
- Lire les résultats avec unités.
- Expliquer les diagnostics et limites.
- Reconstruire le raisonnement sans aide.

Intra prévu le dimanche 25 octobre 2026. La synthèse détaillée, les exemples et les exercices sont accessibles depuis la page d'entrée du module.

# Deux temps de travail

## **PRÉPARER**

R, ressources et correction après une tentative.

## **VÉRIFIER L'AUTONOMIE**

Questions individuelles sans aide ni IA.

Le module 06 prépare les évaluations suivantes. Il n'est pas ajouté à la matière de l'intra. Le matériel d'examen est confirmé dans Brio.

# Lire une ligne avant de calculer

## **OBSERVATION**

Une combinaison mois-succursale.

## **MESURE**

Ventes mensuelles en dollars; score moyen sur 10.

60 lignes peuvent décrire cinq succursales pendant douze mois. Un score de 8 sur 10 n'est pas une proportion de clients satisfaits.

# Types et qualité

| Vérification   | Question utile                             |
|----------------|--------------------------------------------|
| Type et sens   | Quantité, catégorie, date ou identifiant?  |
| Clé            | La paire mois-succursale est-elle répétée? |
| NA             | Quelles variables et combien de valeurs?   |
| Unité et plage | Montant, compte, proportion ou score?      |

Un code numérique peut être une catégorie. NA n'est pas zéro; supprimer une ligne demande une justification.

# Choisir une représentation

| Question                                                                          | Graphique                           |
|-----------------------------------------------------------------------------------|-------------------------------------|
| Une distribution numérique                                                        | Histogramme                         |
| Une mesure entre groupes                                                          | Boîtes à moustaches                 |
| Deux variables numériques                                                         | Nuage de points                     |
| Totaux déjà calculés                                                              | Barres avec <code>geom_col()</code> |
| Lire centre, dispersion, forme et effectif. Un graphique ne prouve pas une cause. |                                     |

# Un nombre ou un ratio?

$$\text{Ventes par client sur la période} = \frac{\sum \text{ventes}}{\sum \text{clients}}.$$

Le ratio total pondère les mois par leur nombre de clients. La moyenne des ratios mensuels donne le même poids à chaque mois. Le dénominateur change la question.

# Du code à la réponse

**1**

importer et  
inspecter

**2**

préparer et  
vérifier

**3**

résumer ou  
modéliser

**4**

interpréter et  
limiter

Les bibliothèques et l'importation doivent être dans le fichier. Redémarrer R puis relancer Render vérifie que l'analyse peut être reconstruite.

# La droite estimée

$$\hat{y} = b_0 + b_1 x.$$

**PENTE**

Différence de réponse moyenne estimée pour une unité de x.

**INTERCEPT**

Valeur estimée à  $x = 0$ ; vérifier la plage et le contexte.

La droite des moindres carrés minimise la somme des résidus au carré. Pour une hausse  $h$  de  $x$ , la différence prédite est  $b_1 \times h$ .

## Exemple : service et satisfaction

$$\widehat{\text{score}} \approx 9,774 - 0,326 \times \text{délai en minutes}.$$

Une minute supplémentaire est associée à un score moyen estimé inférieur d'environ 0,326 point sur 10. La plage observée est 3,6 à 8,7 minutes; zéro minute est hors de cette plage. Données simulées du laboratoire 02.

# Lire la sortie R

| Colonne    | Sens                                  |
|------------|---------------------------------------|
| Estimate   | Coefficient estimé                    |
| Std. Error | Erreur-type du coefficient            |
| t value    | Écart à zéro rapporté à l'erreur-type |
| Pr(> t )   | Valeur p du test bilatéral            |

Une petite valeur p ne mesure ni l'ampleur de l'association ni une causalité. Lire aussi la pente, son intervalle et les diagnostics.

# Tester une pente nulle

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 \neq 0.$$

**P ≤ SEUIL**

Rejeter H0 sous les hypothèses du modèle.

**P > SEUIL**

Ne pas rejeter H0; une pente nulle n'est pas prouvée.

La valeur p est calculée sous H0 et les hypothèses. Elle n'est pas la probabilité que H0 soit vraie.

# Prédiction et résidu

$$e_i = y_i - \hat{y}_i.$$

**$e > 0$**  sous-estimation

**$e < 0$**  surestimation

**Unité de  $y$**  pour le résidu

Une prédiction est une estimation sous le modèle. Vérifier la plage et le contexte; une extrapolation demande une validation supplémentaire.

# Lire les résidus

| Motif                | Signal possible                |
|----------------------|--------------------------------|
| U                    | Forme moyenne insuffisante     |
| Éventail             | Dispersion non constante       |
| Écarts entre groupes | Structure de groupe à examiner |
| Point éloigné        | Valeur et contexte à vérifier  |

Une moyenne globale nulle vient de l'ajustement avec constante. Elle ne valide pas toutes les hypothèses, notamment l'indépendance des mois répétés.

# Lire $R^2$ et corrélation

$$R^2 = 1 - \frac{SSE}{SST}.$$

$R^2$  résume la variation de la réponse décrite sur l'ajustement. Il ne donne pas un pourcentage de prédictions correctes. En régression simple avec constante,  $R^2 = r^2$ ; le signe de la corrélation est perdu.

# Deux intervalles, deux cibles

## CONFIANCE

Incertitude sur la réponse moyenne pour  $x$  donné.

## PRÉDICTION

Incertitude pour une nouvelle observation; inclut sa dispersion.

Au même niveau et scénario, l'intervalle de prédiction est plus large. Les calculs classiques exacts supposent une forme correcte, indépendance, variance constante et normalité des erreurs.

# Trois formes enseignées

| Forme         | Moyenne estimée           |
|---------------|---------------------------|
| Droite        | $b_0 + b_1 x$             |
| Quadratique   | $b_0 + b_1 x + b_2 x^2$   |
| Logarithmique | $b_0 + b_1 \ln(x), x > 0$ |

Les formes restent linéaires en coefficients et s'ajustent avec `lm()`. La réponse demeure dans son unité originale; seul  $x$  est transformé.

# Dans une quadratique

$$\hat{y}(x + h) - \hat{y}(x) = b_1 h + b_2(2xh + h^2).$$

$x$  et  $x^2$  changent ensemble. La variation dépend du point de départ. Utiliser  $x + I(x^2)$ , en gardant le terme simple. Si  $x$  est en milliers de visites, 100 visites valent  $h = 0,1$ .

# Dans un logarithme

$$\hat{y}(x_2) - \hat{y}(x_1) = b_1 \ln(x_2/x_1).$$

Une hausse de 10 % de  $x$  donne  $b_1 \times \ln(1,10)$  unités de réponse. Logarithmique et logistique sont différents. Un logarithme croissant n'a pas de plafond fini; une quadratique peut redescendre.

# Comparer équitablement

- Même cible et unité.
- Mêmes lignes pour ajuster.
- Mêmes observations pour valider.
- Forme, résidus, erreur et interprétation.

Ajouter un carré ne réduit pas le  $R^2$  d'apprentissage sur les mêmes lignes. Le  $R^2$  ajusté pénalise les paramètres, mais ne remplace pas une validation.

# RMSE et choix provisoire

$$\text{RMSE} = \sqrt{n^{-1} \sum_i (y_i - \hat{y}_i)^2}.$$

Cas guidé du module 04 : RMSE de validation d'environ 10 155 \$ pour la droite, 7 237 \$ pour la quadratique et 8 409 \$ pour le logarithme.

La quadratique est le choix provisoire selon ce critère. La validation a servi au choix; elle n'est pas un test final indépendant. Aucun classement universel n'est établi.

# Conclure à la bonne échelle

**RÉSULTAT**

valeur et unités

**DIAGNOSTIC**

vérification  
observée

**DÉCISION**

proportionnée

**LIMITE**

contexte et  
prochaine étape

Une association n'isole pas l'effet d'une intervention. Une prédiction n'est pas une garantie. Les unités mois-succursale ne sont pas des clients individuels.

# Production autonome

- Une première réponse sans aide.
- Une correction expliquée.
- Deux compétences à reprendre.
- Une nouvelle tentative deux jours plus tard.

Huit exercices progressifs et dix questions individuelles sont accessibles depuis la page d'entrée. Les corrigés sont fermés par défaut et s'ouvrent après une tentative.

# Sources du support

- MQT-2101, supports des modules 01 à 04, 2026.
- Laboratoires 01 et 02, questionnaire formatif et fiche de l'intra.
- Données simulées du cours; calculs reproduits dans les exemples commentés.