Synthèse - Résultats binaires et classification

MQT-2101 - Analyse et modélisation des données

Pourquoi ça compte

Que savons-nous avant d’agir et quelles erreurs pouvons-nous accepter?

> Le risque de départ aide à préparer une décision; il ne mesure pas ce qu’un contact changerait.

Objectifs du module

- Définir une cible binaire et des partitions adaptées.
- Interpréter probabilités, cotes et mesures de classification.
- Choisir puis évaluer une règle avant de recommander une action.

Cible, unité et séparation

- Un résultat binaire décrit un événement observable avec une classe positive définie.
- La décision précède la réalisation de la cible : chaque prédicteur doit être disponible à cette origine.
- Séparer l’apprentissage, qui estime les coefficients, la validation, qui choisit une règle, et le test, qui l’évalue après fixation.

Logistique, cotes et probabilités

$$p = \frac{1}{1 + \exp(-\eta)}, \qquad \text{cote} = \frac{p}{1 - p}.$$

- η est le score linéaire du modèle.
- Pour une unité supplémentaire de x, à autres variables fixées, les cotes sont multipliées par $\exp(\beta_1)$.
- Un rapport de cotes n'est pas un rapport de probabilités.

Matrice et mesures

- Vrai positif (VP) : départ ciblé; faux négatif (FN) : départ non ciblé.
- Faux positif (FP) : non-départ ciblé; vrai négatif (VN) : non-départ non ciblé.

Lire les mesures

Sensibilité

$\mathrm{VP}/(\mathrm{VP} + \mathrm{FN})$

Spécificité

$\mathrm{VN}/(\mathrm{VN} + \mathrm{FP})$

Précision

$\mathrm{VP}/(\mathrm{VP} + \mathrm{FP})$

L'exactitude est $(\mathrm{VP} + \mathrm{VN})/N$, où N est le nombre de clients. Un dénominateur nul rend la mesure concernée indéfinie.

Seuil, coût et capacité

- Le seuil transforme une probabilité en classe.
- Pour des probabilités fixées, abaisser le seuil cible au moins autant de clients et de vrais départs.
- La précision peut augmenter ou diminuer. Les coûts et la capacité guident le choix.

Calibration et action

- Une calibration descriptive compare, par groupes de risques prédits, la probabilité moyenne à la fréquence observée.
- Les groupes peuvent être petits et les résultats incertains.
- Le score de Brier résume l’erreur quadratique des probabilités mais ne mesure pas uniquement la calibration.

À retenir

Probabilité

un risque prédit, sans certitude ni effet causal

Règle

choisir en validation avant d’évaluer sur le test

Décision

coûts, capacité et limites explicités

Les deux traces

Rassemblez les productions 10.1 à 10.5, réalisées une seule fois, dans `classification_clients.qmd`. Conservez les exercices de transfert dans `classification_service.qmd`.

Auto-vérification

- Je distingue probabilité, cote et classe prédite.
- Je sépare le choix en validation de l’évaluation sur le test.
- Je justifie les coûts, la capacité et les limites.
- Mes rapports se rendent après redémarrage de R.

Références et crédits

James, Witten, Hastie et Tibshirani (2021), *An Introduction to Statistical Learning*, 2e édition.

Données fictives du cours MQT-2101, Université Laval.